

Introduction

Week 1

Siwon Yun

BCSC 10th

September 27, 2026

Contents I

- ① Goal of Study
 - 뇌인지과학학회 BCSC에 오신 것을 환영합니다.
 - Foreword
- ② 역사 속 HKP의 위치
- ③ Nobel Prize 2024
- ④ 왜 뇌를 모방해야 할까?
- ⑤ 철학
 - Symbolism & Connectionism
 - 현대 AI는 Connectionism인가?
- ⑥ Neuron & McCulloch–Pitts neuron
 - McCulloch–Pitts neuron
 - McCulloch–Pitts neuron의 한계
 - 일반화된 neuron model
 - McCulloch–Pitts neuron의 철학
- ⑦ 병렬 처리
- ⑧ The Issues
 - HKP가 제시하는 네 가지 질문
 - Generalization
 - Hardware
 - Design vs Theory

Goal of Study

§ 뇌인지과학학회 BCSC에 오신 것을 환영합니다.

AI(Artificial Intelligence)와 뇌 인지 과학의 연관성을 고려해 봅시다.

- 뇌에서 획득한 data를 ai 기술을 활용하여 분석
- 뇌를 모방한 model 제작

본 스터디는 후자에 초점을 맞추겠습니다. 즉, 다양한 model을 나열하여 배우는 것보다는, 뇌가 창발하는 지능을 모방하는 방법을 고민하고 탐구합니다.

§ Foreword

a new field is emerging: the study of how computation can be carried out in extensive networks of heavily interconnected processing elements, whether these networks are carbon- or silicon-based.

Christof Koch

Hopfield Model → Boltzmann Machine → DBN으로 model이 발전해 왔습니다. Hopfield의 model은 뇌를 모방하여 만들어졌습니다. 반면, DBN은 공학적 해결 방법과 hybrid로 혼합하여 성능을 높였습니다. 추후, ReLU 등 다양한 기법이 개발되어 ai는 보다 공학적인 길을 걷습니다. 현대 가장 성공적인 model인 transformer를 간단히 살펴보고, 과연 공학적 길을 걸어온 현대 AI가 뇌의 모방에서 완전히 벗어난 것인지를 탐구합니다.




Figure 1: 모델별 명시적 뇌 모방도

사피엔스가 인류의 대서사시를 그리듯, 뇌를 모방하며 시작된 ai가 공학적 요소가 포함되기까지, 그리고 돌고 돌아 다시 뇌 모방적 요소와 연결되는 현재까지의 대서사시를 탐구할 수 있으면 좋겠습니다.

역사 속 HKP의 위치

우리가 처음으로 살펴볼 교재 HKP¹가 deep learning 역사 속 어디에 위치하고 있는지 살펴봅시다.




Figure 2: 책 역사. Lecture가 진행된 1989년 기준

자세한 역사를 위한 참고 자료:

https://drive.google.com/file/d/1vVNUye-1JNInqP4A0704sjtF7gs_MpCI/edit

¹Hertz, Krogh, Palmer — Introduction to the Theory of Neural Computation (1991)

Nobel Prize 2024

2024년 Hopfield model을 제작한 John J. Hopfield와 Boltzmann Machine, DBN을 제작한 Geoffrey Hinton은 nobel 물리학상을 공동 수상하였습니다.



(a) Hopfield



(b) Hinton

Figure 3: 2024 노벨 물리학상 수상자.

왜 뇌를 모방해야 할까?

뇌는 현대 AI보다도 많은 강점을 가집니다. 1991년 출간된 우리 교재에서 뇌의 강점을 찾아 봅시다:

- 강건하고 결함에 내성이 있다 (Robust and fault tolerant) — 매일 뇌세포가 죽어도 기능에 큰 영향이 없다
- 유연하다 (Flexible) — 새로운 환경에 “학습”으로 적응한다
- 불확실한 정보²를 다룰 수 있다 (Fuzzy, probabilistic, noisy, inconsistent)
- 높은 병렬성을 가진다 (Highly parallel)
- 작고, 컴팩트하며, 에너지 소모가 적다 (Small, compact, low power)

이 중 현대 AI가 해결한 것은 **높은 병렬성** 뿐입니다. 이 또한 model의 발전이 아닌 **hardware**(GPU)의 발전으로 이룬 결과입니다.³


²현대 ai는 train data에 noise를 넣어 억지로 학습 시킵니다.

³1991년 당시에는 GPU가 존재하지 아니하였습니다.



Figure 4: BTS 게Setter

<https://lnkd.in/p/gGEbxK7S>




철학


§ Symbolism & Connectionism

AI는 2가지 철학적 기반이 있습니다: Symbolism, Connectionism.⁴

- **Symbolism:** 논리와 규칙 기반. Dartmouth 회의(1956) → 전문가 시스템 → ...; CS 인공지능 개론에서 배우는 역사.
- **Connectionism:** 뉴런의 연결에서 지능이 창발. Hebb(1949) → Hopfield(1982) → Boltzmann → ...; CS에서는 잘 다루지 않는 역사.



(a) 논리회로



(b) 망델브로 집합

Figure 5: 복잡성을 구성하는 논리회로와 복잡성을 창발하는 망델브로 집합

Symbolism과 Connectionism을 간단히 이해하기 위해 Figure 5를 살펴봅시다.

- (a)는 computer의 논리회로입니다. OR, AND, NOT gate를 통해 컴퓨터의 모든 기능을 구성합니다.
- (b)는 망델브로 집합입니다. $z \mapsto z^2 + c$ 라는 하나의 ‘원리’를 통해 창발 되었습니다.

⁴이에 대한 자세한 논의는 다음을 참고하세요: <https://eu-opensci.org/index.php/ejai/article/view/1023>

	Symbolism	Connectionism
단순한 것의 조합	✓	✓
설계 가능 (통제 가능)	✓	× (국소 규칙에서 창발)
결과를 설계자가 예측 ⁵	✓	×
분해하여 추적 가능	✓	×

Table 1: Symbolism과 Connectionism 비교⁶

모델의 기능은 여전히 창발적이지만, 현대 AI의 부품들(ReLU, residual connection 등)은 주로 학습이 잘 되게 하려는 공학적 필요로 하나씩 추가되어 왔습니다. 이 스터디는 반대로, 뇌를 모방한다는 기준으로 모델들을 살펴봅니다.

§ 현대 AI는 Connectionism인가?

예시: Sparse Autoencoder

희소한(몇몇 개의) neuron만 활성화되게 만드는 것을 목표로합니다.

→ 각 neuron에 명시적 의미를 부여하여 해석 가능성을 추구합니다.

하지만, HKP (1991)에 의하면:

"In the brain itself cells die all the time without affecting the function, and this robustness of the biological neural networks has probably been essential to the evolution of intelligence."

뇌는 분산 표현(distributed representation)으로 작동합니다. 개별 neuron에 기능을 귀속시키는 것은 이와 반대 방향입니다.⁷

대개, 공학적인 방법은 Symbolism하며 자연은 fractal과 chaos합니다.

⁵예측 불가가 곧 비결정론을 의미하지는 않습니다.


⁶사실, 이와 관계 없이 neuron, weight, network를 사용한 model은 Connectionism으로 부르는 경향이 있습니다. 하지만, 뇌를 모방하는 목적에 맞게 기준을 강화합니다.

⁷바로 다음 탐구할 McCulloch-Pitts neuron, 추후 탐구할 backpropagation 등을 살펴보면 Symbolism과 Connectionism 중 어느 철학을 따라가는지 고뇌해 보시다.


Neuron & McCulloch–Pitts neuron

뇌의 신경망을 모방하여 computer에서 연산합니다. 뇌 세포의 단위, 즉 neuron을 modeling해 봅시다.

§ McCulloch–Pitts neuron



(a) single neuron



(b) McCulloch–Pitts neuron

Figure 6: 생물학적 neuron과 이를 모방한 McCulloch–Pitts neuron

Figure 6a는 생물학적 neuron입니다. 이는 synapse로 부터 spike를 전달 받습니다. 전위potential가 역치threshold를 넘으면 axon을 통해 다음 neuron으로 spike를 전달합니다. 이 때, 발화fired되었다고 말합니다.

McCulloch–Pitts neuron(cf. Figure 6b)은 이를 모방한 단순한 binary model입니다:

$$n_i(t+1) = \Theta \left(\sum_j w_{ij} n_j(t) - \mu_i \right) \quad (1)$$

각 n_i 는 1 또는 0의 값을 가지며(binary), 시간 t 는 discrete한 값입니다. $\Theta(x)$ 는 step function으로 다음과 같습니다:

$$\Theta(x) = \begin{cases} 1 & \text{if } x \geq 0; \\ 0 & \text{otherwise} \end{cases} \quad (2)$$

가중치 w_{ij} 는 neuron j 에서 neuron i 를 의미하며 다음과 같은 의미를 가집니다:

- $w_{ij} > 0$: excitatory synapse
- $w_{ij} = 0$: 두 neuron간 연결이 없음.
- $w_{ij} < 0$: inhibitory synapse

μ_i 는 threshold 값입니다. summation 값이 이보다 크면 다음 n_i 는 1 값을 가집니다.

§ McCulloch–Pitts neuron의 한계

McCulloch–Pitts neuron은 생물학적 neuron의 극단적 단순화입니다. 실제 neuron과의 차이를 살펴봅시다:

- 실제 neuron은 이진이 아닌 **연속적 반응**(graded response)을 보인다
- 입력의 합산이 **비선형적**(nonlinear)이다 — dendrite 내에서 이미 논리 연산이 일어남
- 단일 출력값이 아닌 **spike의 연속**(pulse sequence)을 생성한다
- 모든 neuron이 동일한 지연 시간을 갖지 않는다⁸
- Synapse에서의 신경전달물질 분비량이 **확률적**(stochastic)으로 변한다

§ 일반화된 neuron model

이러한 한계를 반영하여, step function Θ 를 일반적인 비선형 함수 g^9 로 대체합니다:

McCulloch–Pitts

일반화

$$n_i(t+1) = \Theta\left(\sum_j w_{ij} n_j(t) - \mu_i\right) \implies n_i := g\left(\sum_j w_{ij} n_j - \mu_i\right)$$

출력: 0 또는 1

출력: 연속값

핵심은 g 의 구체적 형태가 아니라 **비선형성**(nonlinearity) 자체¹⁰입니다.

⁸추후 async, sync와 관련된 문제를 야기합니다.

⁹이는 activation function이라고 불립니다.

¹⁰HKP: “it is the nonlinearity that is essential, not its specific form.”. 추후 ReLU라는 activation function이 backpropagation과 함께 현대 ai에 공학적 idea를 첨가한 경의를 살펴봅시다.

§ McCulloch–Pitts neuron의 철학

둘의 논문 제목은 ‘A logical calculus of the ideas immanent in nervous activity’¹¹입니다.

이는 McCulloch–Pitts neuron으로 logic 회로를 구성할 수 있으며, 사람이 weight(w_{ij})를 설계하면 범용 computer를 만들 수 있다고 주장한답니다. 마치, logic 회로를 설계해서 우리의 목적을 이루는 **computer**처럼 :)

즉, McCulloch–Pitts neuron의 weight는 사람이 설계할 수 있는 대상입니다. 앞으로 살펴볼 내용과 함께 보면....

- **McCulloch–Pitts neuron**: weight는 사람이 설계해야 한다.
- **Hopfield network**: 저장할 패턴만 주면 weight가 Hebb 규칙(상관)으로 한 번에 정해진다.
- **Perceptron**: weight가 오류를 줄이는 방향으로 반복 조정된다.

다른 관점에서 바라보면,

- **McCulloch–Pitts neuron**: neuron의 단순한 연결만으로 강력한 기능을 가질 수 있다 → weight는 사람이 설계해야 한다.
- **Hebb rule**: 연결(weight)이 스스로 형성된다.
- **Hopfield network**: 그 연결에서 기억이 창발된다.

¹¹McCulloch & Pitts (1943). ‘logical calculus’와 ‘nervous activity’를 고려하여 Symbolism과 Connectionism을 고려해 봅시다.

병렬 처리




Figure 7: A two-layer perceptron

CS 용어로, 뇌는 10^{11} 개의 processor로 이루어진 병렬parallel system입니다.

“It is worth remarking that the typical cycle time of neurons is a few milliseconds, which is about a million times slower than their silicon counterparts, semiconductor gates. Nevertheless, the brain can do very fast processing for tasks like vision, motor control, and decisions on the basis of incomplete and noisy data, tasks that are far beyond the capacity of a Cray supercomputer. This is obviously possible only because billions of neurons operate simultaneously. Imagine the capabilities of a system which could operate in parallel like this but with switching times of current semiconductor devices!”

HKP서 저자는 능력 $\propto$ 속도 $\times$ 개수임을 가정하여 거대한 병렬성을 이루면 지능이 만들어지리라 기대하고 있습니다. 30년도 더 지난 현재 시점에서 바라보면 저자의 기대는 합당했을까요??¹²

¹²글에 Cray supercomputer라는 말이 나옵니다. 저 당시에는 실용적인 GPU가 존재하지 아니하였습니다.

§ HKP가 제시하는 네 가지 질문

Network를 실제로 구현하려면 다음 질문들에 답해야 합니다:

1. **Architecture:** 층 구조? 연결 방식? Activation function $g(x)$? 동기/비동기 update?
2. **Learning:** 학습이 가능한가, 사전 설계해야 하는가? 예시가 몇 개 필요한가? 정답이 필요한가?
3. **Capability:** 몇 가지 task를 배울 수 있는가? 일반화가 가능한가? 어떤 함수를 표현할 수 있는가?¹³
4. **Hardware:** 어떻게 구현하는가? Hardware vs software?

이 질문들은 서로 독립적이지 아니합니다 — architecture가 capability를 결정하고, capability가 hardware 선택에 영향을 줍니다.

¹³어떤 함수를 표현할 수 있는가에 대한 대답은 BCSC 9th Term 1 statistical understanding on deep learning에서 리뷰한 논문 ‘Approximation by Superpositions of a Sigmoidal Function’이 답합니다.

§ Generalization

“ The reason for much of the excitement about neural networks is their ability to generalize to new situations. ”

→ 다음 시간에 공부할 Hopfield network는 연상기억을 절차로 짜 넣었는지, 아니면 단순한 국소 규칙에서 창발하게 했는지 살펴봅시다. 그리고 연상기억이 일반화와 어디까지 닮았는지도요.

“ But what is meant by sensible generalization is often not clear. ”

→ 우리는 이제 일반화 능력에 큰 관심을 가지지만 일반화 능력은 무엇일까요? 명확한 정의가 가능한들, 명확한 관측이 가능할까요?

§ Hardware

- Neural network VLSI: (!!!)
- Optical computer

병렬성이 거대한 hardware가 AI 기술에 활용될 것임이 예측되고 있습니다. GPU가 활성화 되기 이전에, 너무 많은 연결이 칩이 만들어지는데 어려운 이유라고 합니다. 우리 뇌는 작은 공간에 어떻게 많은 연결을 가질 수 있을까요?




Figure 8: general?^a

^a주의: image 속 general의 뜻과 본 page가 다루는 generalization은 겉표면적으로 의미가 다름.

§ Design vs Theory

이 질문들을 바라보는 두 가지 관점이 있습니다:

Design

“어떻게 만들지?”

성능, 속도, 정확도

→ 현대 AI의 주류

vs

Theory

“왜 이렇게 작동하지?”

원리, 구조, 행동의 이해

→ 본 교재의 관점

“We will generally approach them from a theoretical point of view, rather than from a design one. That is, we will attempt to understand the behavior of networks as a function of their architecture.”

예컨대 Hopfield network의 기억 용량을 두고, “어떻게 하면 더 많이 기억하게 만들까?” (Design)보다 “왜 연상기억이 창발하고, 왜 그 용량에 한계가 생기나?” (Theory)를 묻습니다.

*“But of course the two viewpoints are not independent, and a strong understanding of **principles** is invaluable for good design.”*