

BOLTZMANN MACHINE

볼츠만 머신

목차

홉필드 네트워크 복습

- 기억 저장과 복원
- 에너지 최소화
- 결정론적 동작

홉필드 네트워크의 한계

- 지역 최솟값 문제
- 복잡한 패턴 학습 어려움
- 은닉 표현 부재

볼츠만 머신의 핵심 아이디어

- 확률적 네트워크 전환
- 은닉 유닛 도입
- 볼츠만 분포와 온도

볼츠만 학습 원리

- Clamped/Free 상태
- 좋은 패턴 강화
- 이상한 패턴 약화


볼츠만의 한계

- Clamped/Free 상태
 - 좋은 패턴 강화
 - 이상한 패턴 약화
- + 통계 역학적 관점에서의 볼츠만

볼츠만의 한계현대 딥러닝과의 연결


- RBM과 DBN
- 생성형 AI 기반
- 계산 복잡도 해결

홉필드 네트워크 복습



기억 저장과 복원 메커니즘

- 완전 연결 네트워크 구조
- 패턴을 가중치에 저장
- 손상된 입력 → 완전한 기억 복원
- 연상 기억 시스템
associative memory



에너지 최소화 원리


- 에너지 함수 정의
- 안정 상태 = 에너지 최소
- 항상 에너지 감소 방향

$$S_i \leftarrow \text{sgn} \left(\sum_j w_{ij} S_j \right)$$

결정론적 동작 방식


- 확정적 업데이트 규칙
- 예측 가능한 경로
- 랜덤성 없음
- 같은 입력 → 같은 결과

홉필드 네트워크의 한계



지역 최솟값(local minima) 문제

- 잘못된 골짜기에 빠짐
- 전역 최적해 도달 실패
- 탈출 메커니즘 부재



복잡한 패턴 학습의 어려움

- 저장 용량 제한적
- 패턴 간 간섭 발생
- 복잡한 구조 표현 불가



볼츠만 머신 등장

홉필드 네트워크가 기억, 저장 위주였다면 볼츠만 머신은 숨겨진 특징도 배우고 확률적으로 탐색도 함

볼츠만 머신의 핵심 아이디어

확률적 네트워크로의 전환

- 결정론 → 확률론
- 온도에 따른 랜덤성
- 지역 최솟값 탈출 가능
- 볼츠만 분포 기반 동작




랜덤성

항상 최선처럼 보이는 선택만 하지 않음
확률적으로 상태를 탐색
local minima 탈출 가능
더 좋은 상태(global minima) 탐색




은닉 유닛(hidden unit)의 도입

- 관찰 불가능한 내부 상태
- AI가 혼자 상상하는 공간
- 복잡한 패턴의 추상 표현
- 표현력 대폭 향상




은닉 유닛의 역할과 의미




관찰 가능한 유닛 vs 은닉 유닛

- 관찰 유닛: 입력·출력 데이터
- 은닉 유닛: 눈에 보이지 않는 내부 상태
- 숨겨진 구조 학습으로 표현력 향상



AI가 혼자 상상하는 상태



- 입력 없이 네트워크 자율 동작
- 학습한 패턴을 스스로 생성
- 꿈과 유사한 과정으로 내부 표현 확인



복잡한 패턴의 내부 표현

- 단순한 입출력 매핑을 넘어섬
- 데이터의 고차원 특징 포착
- 추상적 개념을 내부적으로 표현
- 생성 모델의 핵심 요소

볼츠만 머신



현재 뉴런의 입력값

$$h_i = \sum_j w_{ij} S_j$$

주변 뉴런들의 상태(S_i)를 연결강도 (W_{ij})와 곱해서 전부 더한다.

가시 유닛 visible unit

- 입력 유닛: 우리가 직접 보는 데이터 (픽셀, 숫자, 단어 등)

- 출력 유닛: AI가 내놓는 결과값

→ 사람이 직접 확인 가능

은닉 유닛 hidden unit

중간에서 특징을 찾는 뉴런
→ 사람 눈에는 안 보임

ex: 고양이 사진 학습

- 귀 모양
- 눈 위치
- 털 패턴

AI가 스스로 찾아냄!

“뉴런이 켜질 확률”을 구하는 함수

$$g(h) = \frac{1}{1 + \exp(-2\beta h)}$$

- β 값이 작으면 값의 변화가 작아짐, 함수가 완만해짐, 확률이 애매해지기 때문에 온도가 높으면 랜덤성이 커지고, 우유부단
- β 값이 크면 함수가 가팔라짐, 온도가 낮으면 안정적인 상태 선호 랜덤성이 줄어들, 정확하게 결정됨

핵심 문제: 학습 데이터는 은닉 유닛에게 '뭘 해야 하는지' 알려주지 않는다

에너지 함수와 확률적 동작

에너지 함수의 의미

- 낮은 에너지 = 좋은 패턴, 안정된 상태
- 높은 에너지 = 불안정한 상태
- 학습 목표는 에너지 최소화
에너지가 낮은 안정 상태를
찾으려고 움직임

$$H = -\frac{1}{2} \sum_{ij} w_{ij} S_i S_j$$

$$P(S_i = 1) = \frac{1}{1 + e^{-2\beta h_i}}$$

볼츠만 분포 이해하기

- 에너지에 따른 확률 분포
- 에너지 낮은 상태 = 확률 높음
- 에너지 높은 상태 = 확률 낮음
- $P(\text{상태}) \propto e^{(-\beta H)}$
- 전체 확률 합 = 1 (Z로 정규화)

볼츠만-깁스 분포 (Boltzmann-Gibbs distribution)

$$P(S_i) = \frac{e^{-\beta H(S_i)}}{Z}$$

평형 상태에 도달한 뒤 시스템이 특정 상태 {S_i}에 존재할 확률,
에너지가 낮은 상태일수록 더 높은 확률로 등장한다

$$Z = \sum e^{-\beta H}$$


- 분모 Z는 partition function(분배 함수)라고 불리며, 적절한 정규화 상수 역할을 한다.
전체 확률 합을 1로 맞추기 위한 정규화 상수

온도 매개변수의 역할

- T 높음 → 랜덤하게 탐색
- T 낮음 → 결정적으로 행동
- $\beta = 1/T$ (물리학 연결)
- T ↑ 더 넓게 탐색, T ↓ 수렴


$$\beta = \frac{1}{T}$$

볼츠만 학습 규칙 (1): Clamped 상태 $(S_i S_j)_{clamped}$




입력 데이터가 고정된 상태

- 관찰 유닛에 실제 데이터 입력
- 입력값 고정되어 변하지 않음
- 네트워크가 데이터에 맞춰 동작



실제 데이터의 통계 수집

- 고정 상태에서 유닛 간 상관관계 측정
- 함께 활성화되는 유닛 관찰
- 실제 데이터의 패턴과 통계 기록



좋은 패턴 강화하기

- 실제 데이터에서 나타난 연결 강화
- 자주 함께 나타나는 패턴 학습
- 가중치를 증가시키는 방향
- 데이터의 특징을 네트워크에 각인

정답 데이터를 기준으로 뉴런의 상관관계를 관찰

볼츠만 학습 규칙 (2): Free 상태 $\langle S_i S_j \rangle_{free}$

AI가 자유롭게 상상하는 상태

- 입력 없이 네트워크 자율 동작
- 모든 유닛 자유로이 변화
- 학습 기반 생성으로 내부 모델 확인




모델이 만든 데이터의 통계

- 자유 상태에서 유닛 간 상관관계 측정
- 모델 생성 패턴 분석
- 실제 데이터와 비교해 이해도 평가



이상한 패턴 약화하기

- 실제 데이터와 다른 연결 약화
- 잘못 학습된 패턴 제거
- 가중치를 감소시키는 방향
- Clamped와 Free 차이로 학습



입력을 제거(visible 고정x), 네트워크를 자유롭게 두었을 때의 상관관계를 측정, AI가 혼자 만들어낸 뉴런의 상관관계
CLAMPED, FREE 두 항이 모두 필요! FREE 항 없으면 AI가 자기 환상을 학습해버린다

볼츠만 학습 규칙

가중치 업데이트

$$\Delta w_{ij} = \epsilon(\langle S_i S_j \rangle_{clamped} - \langle S_i S_j \rangle_{free})$$

정답 상태에서 같이 켜진 정도 - 자유롭게 돌렸을 때 같이 켜진 정도

실제 데이터에서 자주 나타나는 연결은 강화하고, 네트워크가 혼자 만들어낸 이상한 패턴은 약화시킵니다.

볼츠만 학습 규칙

현재 ai가 만들어내는 확률 분포 R와 우리가 원하는 정답 분포 p가 얼마나 다른지 알아 보기 위해서 "상대 엔트로피(relative entropy; KL divergence)"

볼츠만 머신은 단순히 정답 하나를 맞추는 것이 아니라 원하는 확률 분포 자체를 학습하고자 함.

- 엔트로피: 무질서도 개념
정보이론에서는 "확률 분포의 정보 차이" 정도로 사용
상대 엔트로피가 크다? -> AI의 확률분포와
정답 분포의 차이가 크다

따라서 볼츠만 머신은 상대엔트로피를 줄이는 방향
즉, 가중치를 수정함

$$E = \sum_{\alpha} R_{\alpha} \log \frac{R_{\alpha}}{P_{\alpha}}$$

원하는 확률분포 R



현재 확률분포 P



둘 차이 계산

(상대엔트로피)



오차 줄이는 방향 계산

(gradient descent)



가중치 업데이트

Gradient descent

$$w \leftarrow w - \eta \frac{\partial E}{\partial w}$$

오차가 줄어드는 방향으로 가중치를 업데이트

η (eta) = 얼마나 이동할지

E = 오차

$\partial E / \partial w$ = 오차가 증가하는 방향


볼츠만 학습 규칙

Monte Carlo Simulation

뉴런 상태를 랜덤하게 계속 바꾸어 보면서,
전체 시스템의 평균적인 행동을 추정하는 방법

에너지 낮은 상태일수록 자주 등장


$$P \propto e^{-\beta H}$$



Simulated Annealing


$$\beta = \frac{1}{T}$$

처음에는 높은 온도에서 시작해서 랜덤하게 넓게 탐색하고,
시간이 지나면서 온도를 천천히 낮춰 안정적인 상태로 수렴시키는 방식



통계역학적 관점에서의 볼츠만 머신

$$E = \sum_{\alpha} R_{\alpha} \log \frac{R_{\alpha}}{P_{\alpha}}$$



$$E = E_0 + \beta(\overline{F^{clamped}} - F)$$

$$Z = e^{-\beta F}$$

Z : Partition Function (분배함수)

F : Free Energy (자유에너지)

$\beta=1/T$

에너지 낮을수록 안정적


확률 높은 상태가 됨

볼츠만 머신은 안정적인 확률 구조를 학습

“원하는 데이터 분포”와 “현재 네트워크 분포”의 차이를 줄이는 과정을
물리학적으로 해석하면 자유에너지 차이를 최소화하는 과정이라고 볼 수 있습니다.


왜 볼츠만 머신은 느렸을까?

평형 상태까지 기다려야 함 + 가능한 조합 수가 천문학적 → 역전파 대비 매우 비효율적
모든 유닛 조합을 고려해야 함, 유닛 수에 따라 지수적 증가, Clamped와 Free 상태 각각 계산(느림), 실용적 적용에 큰 장애물



Simulated Annealing

- 온도를 천천히 낮추는 최적화 기법
 - 초기: 넓게 탐색, 후기: 수렴
- 전역 최적해 찾기 위한 방법
- Local minima 탈출 가능
- 매우 많은 반복 계산 필요



Mean Field 근사 방법 결정론적 볼츠만 머신

- 랜덤 샘플링 대신 평균값 사용
- 확률적 계산을 결정론적으로
 - $\langle S_i S_j \rangle \approx m_i \cdot m_j$ 로 근사
- 계산량을 크게 줄이는 방법
- 정확도와 속도의 트레이드오프



Weight Decay 등

가중치가 너무 커지는 것 방지
현대 딥러닝에서도 사용되는 개념
Incremental Rule (ϵ 단계 업데이트)
자동 대칭화로 안정성 향상

현대 딥러닝과의 연결

제한된 볼츠만 머신 (RBM)

- 층 내 연결을 제거한 구조
- 계산 복잡도를 크게 감소
- 효율적인 학습 알고리즘 가능
- 실용적 딥러닝의 시작점

Deep Belief Networks

- RBM을 여러 층으로 쌓은 구조
- 사전 학습 기법으로 활용
- 2006년 딥러닝 부흥의 계기
- 현대 신경망 학습의 기초

생성형 AI의 기반 아이디어

- 데이터 분포를 학습하는 개념
- VAE, GAN 등으로 발전
- 확률적 생성 모델의 원조
- 현대 생성형 AI의 이론적 뿌리

볼츠만은 느렸지만 확률 표현력은 탁월 — 그 아이디어가 현대 생성 AI의 씨앗이 됨