

Active Inference

Chapter 9: Model-Based Data Analysis

Siwon Yun

BCSC 9th

January 10, 2026

Contents I

- ➊ Introduction
 - Model-Based
 - Subjective Model & Objective Model
- ➋ Meta-Bayesian Methods
 - 관찰된 행동(data)에 computational model을 적용하는 이유
 - meta-Bayesian method를 위한 상세 방법
- ➌ Variational Laplace
 - Predictive Coding & Variational Laplace
- ➍ Parametric Empirical Bayes(PEB)

Introduction

§ Model-Based

- **model-free**: reward 값만을 따라 행동하는(e.g., Q-learning)
- **model-based**: 환경의 dynamics model을 학습하여 행동하는(e.g., Active Inference, 목표 지향적 행동)

목표: empirical data를 Active Inference를 통해 이해하기

§ Subjective Model & Objective Model

- **subjective model**: 실제로 작동하고 있는 피험자의 generative model
- **objective model**: 과학자가 예측한 피험자의 generative model

수정된 목표: parameter를 조정(복원)하여 objective model을 subjective model과 가능한 유사하게 만들기 → meta-Baysian method 사용

Meta-Bayesian Methods

meta-Bayesian inference: 행동 관찰을 통해 역으로 generative model을 도출하여 생명체의 inference model에 대하여 추론(inference)하는 것

$$\underbrace{\Pr(u \mid \theta, m)}_{\text{likelihood}} \underbrace{\Pr(\theta \mid m)}_{\text{prior}} = \underbrace{\Pr(\theta \mid u, m)}_{\text{posterior}} \underbrace{\Pr(u \mid m)}_{\text{evidence}} \quad (1)$$

여기서, u : 관찰된 행동(data), θ : 모델 parameter, m : 모델

§ 관찰된 행동(data)에 computational model을 적용하는 이유

- i) **computational phenotyping:** 개인(or 특정 집단)의 행동을 설명하는 모델 parameter 추정
이를 위해서는 특정 measure(e.g., neuroimaging과 기능의 연관성 지표)를 정의해야 함

Note: Equation 1에서 posterior $\Pr(\theta \mid u, m)$ 를 추정하는 과정

- ii) **model comparison:** 다양한 모델이 주어진 data를 얼마나 잘 설명하는지 비교

Note: Equation 1에서 evidence $\Pr(u \mid m)$ 를 추정하는 과정

Meta-Bayesian Methods




Figure 1: Relationship between the subjective and objective models of meta-Bayesian inference. Inner dashed box: Subjective model assumed to be used by an experimental subject. This could be a POMDP model as illustrated or some other form of model. The important features are that it depends on parameters (θ) whose value we do not know and that it generates sensory data (o). Outer dashed box: Experimenter’s objective model (m) includes prior beliefs about the parameters and predicts the behavior (u) we would expect on presenting experimental stimuli (sensory data from the subjective model’s perspective). Crucially, the likelihood distribution of the objective model depends on the subjective model. This means we evaluate the likelihood of parameters taking a particular value as follows. First, we incorporate the parameters in the subjective model. We then use the Active Inference schemes described in previous chapters to solve this model, presenting our experimental stimuli as sensory data, and infer a distribution over the most probable course of action. Finally, we evaluate the probability of the observed actions or choices, given this distribution. This is the likelihood of observed behavior given parameters and stimuli—i.e., the likelihood distribution in the objective model.

Meta-Bayesian Methods

§ meta-Bayesian method를 위한 상세 방법

- **Section 3:** Equation 1의 posterior $\Pr(\theta | u, m)$ 을 추정을 위해 variational Laplace 방법을 사용

Note: evidence $\Pr(u | m)$ 는 variational laplace 과정서 자동으로 구해짐. 책의 appendix A.3.2 참고

- **Section 4:** 여러 피험자의 data를 동시에 분석하는 parametric empirical Bayes(PEB) 방법 소개

Variational Laplace

§ Predictive Coding & Variational Laplace

- **predictive coding**: 매순간 들어오는 감각(o)와 예측의 오차를 줄여 상태(s) 업데이트 $\rightarrow F$ 최소화
- **variational Laplace**: data와 model의 예측의 오차를 줄여 parameter(θ) 업데이트 $\rightarrow F$ 최소화

$\Rightarrow$ 둘 모두 F 를 objective function으로 하는 isomorphic인 상황

$$\begin{aligned}\mathcal{L} &= \log \Pr(\tilde{u} \mid \theta, m, \tilde{o}) \\ \Pr(\tilde{u} \mid \theta, m, \tilde{o}) &= \tilde{u} \cdot \sigma(\theta_{\alpha} \log \tilde{u}) \\ \tilde{u} &= \boldsymbol{\pi} \cdot U \\ \boldsymbol{\pi} &= \arg \min_{\boldsymbol{\pi}} F\end{aligned}\tag{2}$$

- **subject**: π 를 최소화할 수 있는 정책 $\boldsymbol{\pi}$ 를 찾음 $\rightarrow$ 정책에 기반한 행동 $\tilde{u}$ 생성
- **scientist**: 해당 행동이 나올 확률을 계산함(likelihood)

Variational Laplace

variational Laplace를 고려하여 Equation 2을 근사하면...

$$\begin{aligned}\log \Pr(\tilde{u} \mid m, \tilde{o}) &\approx \mathcal{L}(\mu) + \frac{1}{2} \left(\varepsilon \cdot \Pi^{(1)} \varepsilon + \log \left| \nabla_{\mu\mu} \mathcal{L}(\mu) - \Pi^{(1)} \right| \right) \\ \varepsilon &= \eta - \mu \\ \mu &= \arg \max_{\mu} \left\{ \mathcal{L}(\mu) - \frac{1}{2} \left(\varepsilon \cdot \Pi^{(1)} \varepsilon + \log \left| \nabla_{\mu\mu} \mathcal{L}(\mu) - \Pi^{(1)} \right| \right) \right\}\end{aligned}\tag{3}$$

Laplace approximation을 적용하고, Gaussian으로 근사하기 위해 3번째 항까지 구함.
이 중 2번째 항은 최빈값(mode)에 의해 0이 되어 생략함.¹

$$\dot{\mu} = \nabla_{\mu} \mathcal{L}(\mu) + \Pi^{(1)} \varepsilon\tag{4}$$

gradient descent를 통해 최적값을 구함

¹여기서야 계산의 효율을 위해 근사하지만, predictive coding서 미분하고 근사하는 것이 정당한가??

Parametric Empirical Bayes(PEB)

목표: 여러 피험자의 data를 동시에 분석하기 → 집단의 공통된 parameter나 개인을 대변하는 parameter를 찾을 수 있음.

$$\Pr(\theta \mid \beta, X) = \mathcal{N}(X\beta, \Pi^{(2)}) \quad (5)$$

² 여기서 X 는 각 참가자를 행으로, 각 특성 변수를 열로하는 matrix이며, β 는 영향력의 크기, 즉 가중치 값

²covariance Σ 대신 precision $\Pi = \Sigma^{-1}$ 사용하는 것은 정보 이론의 관점을 위함(또는 계산 효율 증진), $\Pi^{(2)}$ 는 개인이 아닌 집단 수준의 정밀도를 뜻함




Figure 2: Roadmap of the six-step