

Additional Study

윤시원, 서효정

현대 AI Model과 Active Inference 비교

작성자: 윤시원

현대 AI model(e.g., LLM, ANN)의 문제점을 살펴보고 Active Inference와 비교하였다.

A.1 No Real-Time Update

현대 LLM model은 data를 가지고 학습을 통해 weight 값을 변화시킨다. 하지만 사용자와 대화하는 경우 frozen weight를 사용하여 실시간 학습이 불가하다. 반면 Active Inference는 연속 시간에서 세상과 생명체가 관찰과 행동을 통해 서로 상호작용함을 가정한다.





그림 A.1: 현대 LLM의 frozen weight 구조와 Active Inference의 실시간 상호작용 비교

A.2 Collapsed Markov Blanket

현대 LLM은 학습한 data를 학습하여 앞으로 다음 단어를 예측한다. 이러한 model은 공감을 나타낸 문헌들을 학습하여 인간의 공감을 흉내낼 수는 있으나 상대의 상황을 자신의 상황으로 simulation(Theory of Mind, ToM)하여 나타나는 진정한 의미의 공감이 불가하다. 비단 ToM의 어려움뿐 아니라 계층 model의 부재로 깊은 temporal depth를 가질 수 없으며 이는 높은 temporal depth를 필요로 하는 신뢰, 용서, 허상, 종교, 더 나아가 공동체를 형성하는 데 어려울 수 있다.



Active Inference

: action-perception loop

그림 A.2: Active Inference 에이전트의 실시간 업데이트 메커니즘

A.3 Lacks First Principles

ANN은 해결하고자 하는 문제를 최적화 문제로 바꾸어 해결하는 기법이다. 하지만, 이 방법이 현실에서 작동해야 한다는 원리가 없다. Active Inference는 Hamiltonian을 생명체의 first principles을 만족함을 주장한다.

Experimental Validation of the Free-Energy Principle with In Vitro Neural Networks

작성자: 서효정

교재 내용을 기반으로 자유 주제를 선정하여 후속 스터디를 진행하였다. 본 파트에서는 논문 리딩 결과를 정리한다.

A.1 논문 핵심 요약

주제는 실제 생물학적 신경 network(in vitro)가 free energy 최소화를 통해 학습하고 환경에 적응하는지를 실험적으로 검증하는 것이다.

배경으로, Karl Friston이 제안한 free energy principle은 지각이 있는 존재가 자신의 내부 model과 외부 환경 사이의 불일치(surprise 또는 free energy)를 최소화하려는 방향으로 행동하고 학습한다고 설명한다. 하지만 그동안은 주로 수학적 modeling에 그쳤고, 실제 neuron 수준에서의 증거는 부족하였다.

실험 방법으로는, 쥐의 뇌 세포를 배양한 신경 network(MEA, Multi-Electrode Array)에 특정 전기 자극 pattern을 주어 환경을 simulation하고, neuron들이 이 자극에 어떻게 반응하고 학습하는지를 관찰하였다.

결과적으로, 실제 neuron 집단이 free energy를 최소화하는 방향으로 연결성(synaptic plasticity)을 수정하며, 외부 자극을 예측하는 내부 model을 형성한다는 것을 확인하였다.

A.2 역공학 접근의 중요성

이 논문의 또 하나의 중요한 특징은 접근 방식 자체에 있다. 기존 연구들은 보통 뇌가 Bayesian inference를 한다고 가정한 뒤 그 가정에 맞는 update 규칙을 설계하는 방식이었다. 그러나 이 논문은 반대로 접근한다. 실제 신경망의 반응을 먼저 관찰한 다음, 그 반응을 가장 잘 설명하는 generative model이 무엇인지 역으로 추론한다.

이 접근이 중요한 이유는 두 가지이다. 첫째, 생물학적 신경망이 실제로 어떤 세계 model을 사용하고 있는지를 추정할 수 있다. 둘째, 그 generative model을 알게 되면 단순한 사후 설명을 넘어 앞으로의 학습과 자기 조직화를 정량적으로 예측할 수 있다. 즉, 이 연구는 해석 가능성뿐만 아니라 예측 가능성을 동시에 확보하려는 시도라고 볼 수 있다.

A.3 실험적 검증: 시험관 내 신경망

이 접근이 실제로 검증되었는지를 살펴보면, 연구진은 쥐 배아의 피질 신경세포로 구성된 시험관 내(in vitro) 신경망을 사용하였다. 그리고 이 신경망의 자극-반응 pattern을 가장 잘 설명하는 POMDP 기반 generative model을 역설계하였다.

그다음, 이 generative model로부터 가소성 규칙을 도출하고 실제 신경망이 시간에 따라 어떻게 자기 조직화되는지를 예측하였다. 그 결과, 실제 신경망의 변화는 free energy 최소화의 경사 하강 법과 매우 잘 일치하였다. 즉, 이 연구는 이론이 data를 설명하는 데 그치지 않고 실제 생물학적 변화를 예측한다는 점을 보여준다.

A.4 신경 신호와 Bayesian 변수의 대응 관계

이 논문에서 특히 주목할 점은 신경학적 변수와 Bayesian 변수 사이의 구체적인 대응 관계를 제시하였다는 것이다. 실험 결과에 따르면, 신경 활동은 hidden state의 posterior를 encoding하고, 기저 흥분성은 상태에 대한 prior를, 시냅스 강도는 model parameter의 posterior를 encoding하는 것으로 해석된다.

즉, 이 신경망은 단순한 값이 아니라 실제로 확률 분포를 표현하고 조정하는 system으로 이해할 수 있다. 이러한 점은 이 연구를 단순한 비유 수준이 아니라 수학적으로 엄밀한 이론과 연결시키는 핵심 요소이다.

A.5 단순한 Hebbian Learning의 한계

이 논문은 단순한 Hebbian learning이 왜 충분하지 않은지도 설명한다. 단순 Hebbian learning은 사실상 잘못된 prior를 가진 비최적화된 generative model에 해당한다.

특히 blind source separation 문제를 제대로 해결하기 위해서는 Hebbian plasticity와 항상성 plasticity의 균형이 필요하다고 주장한다. 그리고 이러한 균형이 필요한 이유는 free energy principle을 통해서만 일관되게 설명될 수 있다. 즉, 이 연구는 특정 학습 규칙이 작동한다는 사실을 넘어서 왜 그러한 규칙이어야 하는지를 이론적으로 정당화한다.

A.6 정신 질환, 약물, 지각 왜곡과의 연결

이 논문은 이론적 논의를 넘어 정신 질환과 약물 효과까지 연결한다. 연구에서 기저 흥분성은 prior에 해당한다. 따라서 prior가 왜곡되면 지각 자체도 왜곡된다.

이 관점은 환각, 망상, 그리고 항불안제나 환각제가 지각에 미치는 영향을 하나의 통합된 framework로 설명할 수 있게 한다. 즉, 정신 질환을 단순한 이상 현상이 아니라 확률 추론 system의 오류로 이해할 수 있다.

A.7 AI 및 뉴로모픽 컴퓨팅으로의 확장

이 논문은 AI로의 확장 가능성도 제시한다. Free energy 기반 학습은 역전파가 필요 없고 국소 정보만으로 작동하며 생물학적으로 타당하다.

이러한 특성은 저전력, 고효율, 해석 가능한 AI 설계로 이어질 수 있다. 즉, 이 연구는 뇌 이론인 동시에 차세대 AI algorithm의 후보로도 볼 수 있다.

A.8 결론

정리하면 이 연구는 다음과 같은 점을 보여준다. 첫째, free energy principle은 실제 신경망을 정량적으로 예측할 수 있다. 둘째, 추론과 학습을 하나의 원리로 통합한다. 셋째, 생물학적 data와 이론을 직접적으로 연결한다. 넷째, 정신 질환, AI, 뇌과학 전반에 응용 가능하다.

요약하면, 이 연구는 free energy principle이 단순한 설명 이론이 아니라 실제 생물학적 신경망의 추론, 학습, 자기 조직화를 정량적으로 예측할 수 있는 법칙임을 실험적으로 입증하였다.