

Chapter 4: The Generative Models of Active Inference

윤시원

Active Inference에서 우리의 뇌는 generative model이다. 이러한 관점에서 우리의 뇌는 2가지 시간 축에 기반하여 분류 가능하다: 1) 이산 시간 (e.g., 결정을 내리는 상황), 2) 연속 시간 (e.g., 생명체의 몸을 움직이는 상황). 본 chapter에서는 기본적인 generative model의 수학적 탐구부터 2가지 시간 축에 대한 기본적인 모델에 대하여 공부하였다. 다만, 분량을 위하여 본 chapter에서는 이산 시간에 대한 model만을 작성하였다.

4.1 Bayes' Theorem

Generative model은 model evidence $\Pr(y)$ 를 높이는 것과 동치이다. 하지만 이는 실질적으로 직접 구하는 데 어려움이 있어, generative model은 이를 최적화 문제로 치환하여 근사한다.

참고: 확률의 곱과 정보의 합

두 확률의 곱은 정보의 합과 관련 있다:

$$\mathfrak{S}(x, y) = \mathfrak{S}(x) + \mathfrak{S}(y) \quad (4.1)$$

이를 Bayes' theorem에 적용하면 prior 정보와 likelihood 정보를 통해 posterior 정보를 얻을 수 있음을 알 수 있다.

$$\mathfrak{S}(x) + \mathfrak{S}(y|x) = \mathfrak{S}(x|y) + \mathfrak{S}(y) \quad (4.2)$$

$\Pr(y)$ 를 구하는 문제를 최적화 문제로 치환하기 위해 Jensen 부등식을 이용한다.

참고: Jensen's Inequality

오목 함수 ϕ 와 random variable X 에 대하여 다음이 만족한다:

$$\mathbb{E}[\phi(X)] \leq \phi(\mathbb{E}[X]) \quad (4.3)$$

$\log$ 함수의 음값은 오목함수이기에 Jensen 부등식을 적용하면 다음을 만족한다: $\mathbb{E}[\log(X)] \leq \log(\mathbb{E}[X])$.

Log evidence $\log \Pr(y)$ 에 대하여 approximate posterior $Q(x)$ 를 가정하고 Jensen 부등식을 적용하면 다음과 같은 결과를 얻을 수 있다:

$$\begin{aligned} \log \Pr(y) &= \log \sum_x \Pr(y, x) = \log \sum_x Q(x) \frac{\Pr(y, x)}{Q(x)} \\ &= \log \mathbb{E}_{Q(x)} \left[\frac{\Pr(y, x)}{Q(x)} \right] \geq \mathbb{E}_{Q(x)} \left[\log \frac{\Pr(y, x)}{Q(x)} \right] =: -F[Q, y] \end{aligned} \quad (4.4)$$




그림 4.1: Logarithmic function providing intuition for Jensen's inequality

이를 정리하면 다음과 같다:

$$F[Q, y] = D_{\text{KL}}[Q(x) \| P(x|y)] - \log \Pr(y) \quad (4.5)$$

Equation ??에서 $F[Q, y]$ 는 variational free energy이며, F 를 최소화함으로써 log evidence 값을 높일 수 있음을 알 수 있다. 앞서 언급한 generative model의 목표와 이는 일치한다. Variational free energy는 complexity ($D_{\text{KL}}[Q \| P]$)와 accuracy ($\mathbb{E}_Q[\log \Pr(y | x)]$)로 분류 가능하다. 이는 데이터를 정확하게 설명하되(accuracy 최대화), 불필요하게 복잡한 가정을 지양하고 기존 믿음을 유지하려는(complexity 최소화) Occam's razor 원칙을 수학적으로 구현한 것이다.

4.2 Generative Models

Free energy를 계산하기 위해 다음 3가지의 요소가 필요하다: data y , 변분 분포 $Q(x)$ 의 집합, 그리고 generative model $\Pr(x, y)$. 이때 각 생명체는 고유한 generative model을 가지기에 서로 다른 출력을 생성한다.

Active Inference에서는 다음 두 형식의 generative model이 사용된다: discrete model, continuous model. Discrete model의 경우 discrete한 시간에서 작동하며 선택과 같은 인지 기능을 해당 model로 modeling할 수 있다. 반면, continuous model의 경우 continuous한 시간에서 작동하며 움직임 등 연속성이 필요한 요소를 modeling한다.

Figure ??의 (a)는 discrete model의 대표적 예인 Partially Observable Markov Decision Process (POMDP)이며, (b)는 continuous model의 대표적인 예이다. 본 chapter에서는 POMDP를 중점으로 소개한다. POMDP는 시간에 따라 진화하는 상태 열(s)로 설명된다. 각 discrete한 시간 step에서 상태는 이전 상태와 agent가 목표한 policy(π)에 의존한다. 최종적으로 상태는 observation(o)을 생성한다.




그림 4.2: Two dynamic generative models