

Chapter 7: Active Inference in Discrete Time

서효정

〈Active Inference〉 7장은 이 이론을 실제 시스템(생물학적 혹은 인공적)에 구현할 때 가장 핵심이 되는 이산 시간(discrete time) model을 다룬다. 앞서 개념적으로 설명된 Active Inference라는 이론을 실제로 어떻게 쓰이는지, 구체적인 예를 통해 보여주겠다는 것이 이 장의 목적이다. 이는 뇌가 어떻게 불연속적인 행동(선택)을 결정하고, 정보를 탐색하며, 계층적인 구조를 통해 복잡한 인지 기능을 수행하는지 이해하는 데 필수적이다.

7.1 개요: 이산 시간(Discrete Time) 모델의 필요성

Active Inference 이론을 실제 시스템에 구현하기 위한 핵심 요소로서 이산 시간 model을 제시한다. 뇌의 인지 과정은 연속적인 환경 속에서도 saccade와 같은 불연속적 정보 수집 단계를 기반으로 작동하며, 각 시간 단계마다 감각 결과(o)를 통해 숨겨진 상태(s)를 역추론하고 다음 행동을 결정한다. 이를 설명하기 위해 본문은 POMDP(Partially Observable Markov Decision Process)를 model의 틀로 사용한다. 이러한 이산 시간 추론 구조는 theta rhythm과 같은 신경생물학적 리듬 및 hierarchical inference 개념과 정합적으로 연결되며, free energy principle이 실제 신경 활동과 행동으로 구현되는 방식을 설명한다.

7.2 Hidden Markov Model




그림 7.1: Hidden Markov Model

Hidden Markov Model (HMM)은 4장에서 도입된 표기법을 사용하여 시간에 따라 변화하는 상태열(s)을 표현한다. 각 시점의 상태는 관측 가능한 결과(o)를 생성하며, 현재 상태는 직전 상태에만 의존하는 Markov 성질을 가진다. 이러한 상태 전이는 전이 행렬(B)로 표현되며, 초기 상태는 사전 분포(D)에 의해 결정된다. 7장에서는 이러한 이산 시간 문제를 다루는 Active Inference model을 HMM 또는 POMDP의 형태로 정식화한다. 제시된 예시는 지각 처리 model과 이산적 포식 선택 model로, 이는 보상을 획득하기 위해 의사결정 지점에서 좌·우 중 하나를 선택하는 문제로 구성된다. 또한 정보 탐색, 학습, 새로움 추구와 같은 과정 역시 이산 시간 Active Inference의 틀 안에서 다루어진다.

7.3 Epistemic Value

정보 탐색(information seeking)의 수학적 원리를 epistemic value 개념을 통해 설명한다. Epistemic value는 agent가 단순한 보상 획득(exploitation)을 넘어 탐색(exploration)을 수행하는 생물학적 동기를 정식화한 지표이다. 제시된 수식 $I(\pi)$ 는 특정 행동 policy(π)이 기대되는 정보 획득량을 나타내며, 이는 여러 동등한 방식으로 해석될 수 있다.

$$\begin{aligned}
 \underbrace{I(\pi)}_{\text{Epistemic value}} &= \underbrace{H[Q(\tilde{o}|\pi)]}_{\text{Post. pred. entropy}} - \underbrace{E_{Q(\tilde{s}|\pi)}[H[P(\tilde{o}|\tilde{s})]]}_{\text{Expected ambiguity}} \\
 &= \underbrace{D_{KL}[P(\tilde{o}|\tilde{s})Q(\tilde{s}|\pi) \parallel Q(\tilde{o}|\pi)Q(\tilde{s}|\pi)]}_{\text{Mutual information}} \\
 &= \underbrace{E_{Q(\tilde{o}|\pi)}[D_{KL}[Q(\tilde{s}|\pi, \tilde{o}) \parallel Q(\tilde{s}|\pi)]]}_{\text{Information gain, salience, Bayesian surprise}} ; \quad Q(\tilde{s}|\pi, \tilde{o}) \triangleq \frac{P(\tilde{o}|\tilde{s})Q(\tilde{s}|\pi)}{Q(\tilde{o}|\pi)} \quad (7.1)
 \end{aligned}$$

Epistemic value는 특정 행동이 내부 신념 또는 상태 추정에 얼마나 큰 변화를 유발하는지를 정량화한다. 이에 따라 agent는 정보 이득이 최대화되는 행동을 선택하며, 이러한 메커니즘을 통해 정보 탐색 이후 보상 획득으로 이어지는 효율적인 생존 전략이 자연스럽게 도출된다.

7.4 실제 신경 신호(LFP)와 계층적 추론




그림 7.2: 서로 다른 시간 척도에서의 계층적 추론과 LFP 신호

서로 다른 시간 척도(timescale)를 갖는 정보가 뇌에서 어떻게 계층적으로 처리되는지를 보여 준다. 상위 계층(Level 2)은 하위 계층(Level 1)에 비해 더 긴 시간 동안 유지되며, 하위 계층에서 반복적인 상태 전이가 발생하는 동안 하나의 맥락(context)을 안정적으로 유지한다. 이와 같은 시간적 분리는 단기적인 감각 변화와 장기적인 맥락 추론을 동시에 가능하게 한다.

상위 계층의 상태는 직접 관찰되지 않으며, 하위 계층의 prior로 작용하여 하위 계층의 추론을 제약한다. 이러한 구조를 통해 상위 계층은 하위 계층의 해석 공간을 제한하고, 하위 계층은 상위

계층이 제공한 맥락 내에서 빠른 추론과 상태 전이를 수행한다. 상·하위 계층은 동일한 POMDP 구조를 공유하며, 이는 동일한 추론 algorithm이 계층적으로 반복 적용됨을 의미한다.

본 model은 문장(sentence)과 단어(word)와 같이 서로 다른 시간 척도를 갖는 인지 요소 간의 상호작용을 모사한다. 또한 model 하단에 제시된 LFP 신호는 Active Inference에서의 prediction error에 대응하며, 새로운 단어의 인식이나 문맥 변화에 따른 신념 갱신 과정이 신경 신호 수준에서 나타남을 보여준다.