

Probabilistic Computational Neuroscience

확률적 뇌 신경 과학

BCSC 9기 Term 2 | 성과물 공유 학회

윤시원 | 광수현 | 김민선 | 서효정 | 이서영 | 이서현(건국대) | 이서현(성신여대) | 임수빈

Contents

- I. 스터디 소개
- II. 확률 모델의 실제 적용 — 2조
- III. Active Inference 이론 — 1조
- IV. 관련 공모전 참여 — 2조


스터디 소개

활동 개요

스터디명: Probabilistic Computational Neuroscience


목표: 확률 이론을 통한 뇌 이해

과정:



활동 진행 방식

2개의 조 구성



스터디 소개

2조 — 확률 모델링

교재

Bayesian Models of Perception and Action: An Introduction
(Ma, Kording & Goldreich)

학습 방향

- 실제 상황을 확률 모델로 표현하는 방법
- 다양한 예시를 통한 확률적 뇌 과학의 적용




Figure: Bayesian Models of Perception and Action

1조 — Active Inference

교재

Active Inference: The Free Energy Principle in Mind, Brain, and Behavior
(Parr, Pezzulo & Friston)

학습 방향

- 이론의 수식적 해석 방법 학습
- 뇌가 '왜' 그리고 '어떻게' 추론하는지




Figure: Active Inference

Part I

확률 모델의 실제 적용 — 2조

공의 위치 지각과 실시간 궤적 추적

Perceptual Inference and Dynamic Tracking of a Moving Target

지각적 추론(Bayesian Inference)

관찰(Observation)을 통해 공의 위치를 지각(Percept)으로 변환 후 실제 세계를 구성

$$p(H|obs) = \frac{p(obs|H)p(H)}{p(obs)}$$

$$p(\text{shiny}|\text{wet}) = 0.8;$$

$$p(\text{not shiny}|\text{wet}) = 0.2;$$

$$p(\text{shiny}|\text{dry}) = 0.4;$$

$$p(\text{not shiny}|\text{dry}) = 0.6.$$


다중 감각 단서 통합 (Multisensory Cue Combination)

시각과 청각 정보를 정밀도(Precision, $J=1/\sigma^2$) 기반으로 가중 통합


$$\mu_{post} = \frac{J_A x_A + J_V x_V}{J_A + J_V}$$

실시간 추적 (Dynamic Tracking)

마르코프 성질(Markov property)를 사용하여 실시간으로 위치 예측과 업데이트



$$\sigma_{prior,t}^2 = \sigma_{post,t-1}^2 + \sigma_s^2$$



위치 추론 기반 최적의 행동 선택

Optimal action: Decision Making under Uncertainty

기대 효용 (Expected Utility)

- 사후 확률과 효용을 결합해 보상 극대화 및 비용 최소화

$$EU(a, x) = \int U(s, a)p(s|x)ds$$

최적 행동 (Action)

- 운동 노이즈를 고려하여 기대 효용이 가장 높은 지점 선택


	World State	
	Rain prob. = 0.3	No rain prob. = 0.7
Action	Do not take umbrella wet & cold cost = 90	dry & happy cost = 0
	Take umbrella slightly damp cost = 10	dry & burdened cost = 5

	World State	
	Rain prob. = 0.3	No rain prob. = 0.7
Action	Do not take umbrella wet & cold cost = 40	dry & happy cost = 0
	Take umbrella slightly damp cost = 20	dry & burdened cost = 10


노이즈 (Decision Noise)

- 소프트 맥스 규칙을 통한 행동 선택의 확률적 모델링

$$p(a) \propto e^{\beta EU(a)}$$



측정 노이즈 하에서의 베이지안 추론



음원 위치 추정 실험 사례

실제 소리는 특정 지점에서 발생하지만, 인간의 청각 시스템은 감각

(σ)로 인해 불확실한 측정치(x)만을 얻게 됩니다. 또한, 실험

정면($\mu=0$)에서 더 자주 발생하도록 설정되어 있어, 관찰자는


$$\text{사후 확률 평균 수식: } \mu_{post} = \frac{Jx + J_s\mu}{J + J_s}$$

X : 감각 측정치, μ : 소리가 정면에서 날 것이라는 사전

=> 불확실한 감각 정보와 기존 지식을 각각의

가중 평균하여 최종 지각치를 결정하는 과정


측정 노이즈 하에서의 베이지안 추론



음원이 위치할 수 있는 실제 지점(s)과 감각 노이즈로 인해 뇌가 받아들이는 측정치(x)의 확률 분포를 보여주는 그래프

추론으로서의 학습 The Low Road

무인도 강수 확률 학습 사례




관찰자는 매일 비가 오는지 여부(x_t)를 관찰하며 그 지역의 실제 강수 확률(r)을

$$\text{업데이트 수식: } \hat{r}_t = \hat{r}_{t-1} + \frac{1}{t+2}(x_t - \hat{r}_{t-1})$$

x_t : 오늘의 날씨 관찰값 $\hat{r}_{t-1}$: 어제까지의 예측치

→ 실제 결과와 이전 기대치 사이의 차이인 '예측 오차'를 바탕으로 세상의 규칙에 대한 믿음을 점진적으로 수정함을 나타내는 과정


추론으로서의 학습 The Low Road



3일간의 구체적인 관찰(건조-비-건조)에 따라 강수 확률 r 에 대한 관찰자의 믿음이 업데이트되는 과정을 보여주는 그래프

변별과 탐지

종양 유무를 판단하는 탐지 사례



관찰자는 노이즈 섞인 이미지(x)를 보고
'종양 있음(s +)'과 '없음(s -)'


$$\text{최적 결정 기준 수식: } k_{MAP} = \bar{s} - \frac{\sigma^2}{\Delta s} \log \frac{p(s_+)}{p(s_-)}$$

σ : 감각 노이즈의 크기 $p(s_+)/p(s_-)$: 두 가설의 사전 확률 비율


=> 감각 정보뿐만 아니라 가설이 발생할 확률(사전 확률)까지 고려하여
정확도를 극대화하는 임계값을 설정하는 과정

변별과 탐지

(A)



(B)



최적 결정 경계(k_{MAP})를 기준으로 측정치가 어느 영역에 속하느냐에 따라 적중 (Hit)과
허위 경보(False Alarm) 확률이 면적으로 어떻게 결정되는지 보여주는 그래프


비대칭적 이진 분류 Embedded Class Task와 Generative Model

Embedded Class(매립 구조)에서의 비대칭적 이진 분류 모델

현실 세계의 범주는 비대칭적인 구조가 많음: e.g., 친구 vs 타인

Embedded Class: 좁은 범위의 범주가 넓은 범위의 범주 안에 포함된 형태

Generative Model: 범주(C) $\rightarrow$ 자극(s) $\rightarrow$ 측정값(x)의 인과 관계



Examples of Class 1 (좁은 범주)



Examples of Class 2 (넓은 범주)



(각 범주를 대표하는)
Gabor stimulus

- 범주 조건부 자극 분포 (CCSD)

$$p(s|C) = \begin{cases} \mathcal{N}(s; 0, \sigma_1^2) & \text{if } C = 1 \text{ (Narrow)} \\ \mathcal{N}(s; 0, \sigma_2^2) & \text{if } C = 2 \text{ (Wide)} \end{cases}$$

- 클래스 가능도 (Class Likelihood)

$$L(C; x) = p(x|C) = \mathcal{N}(x; 0, \sigma^2 + \sigma_C^2)$$

최적의 베이저안 관찰자:

자신의 내부 노이즈와 외부 범주 변동성 통합 $\rightarrow$ 비선형적 결정 경계 형성



비대칭적 이진 분류 이차식 의사결정과 모호성(Ambiguity)

Embedded Class에서의 비대칭적 이진 분류 모델

이차식 로그 사후 확률: 로그 사후 확률 비가 측정값 x 의 제곱에 비례함

노이즈의 영향: 노이즈(σ)가 커질수록 범주 1을 선택하는 판단 영역이 넓어짐

최종 의사결정 규칙: $|x| < \text{criterion}$ 일 때만 범주 1(좁은 범주)로 판단



Definition. 로그 사후 확률 비 (d)

$$d = \underbrace{\log \frac{p(C=1)}{p(C=2)} + \frac{1}{2} \log \frac{\sigma^2 + \sigma_2^2}{\sigma^2 + \sigma_1^2}}_{\text{Constant}} - \underbrace{\frac{x^2}{2} \left(\frac{1}{\sigma^2 + \sigma_1^2} - \frac{1}{\sigma^2 + \sigma_2^2} \right)}_{d \text{가 측정값 } x \text{에 대해 선형이 아닌 이차식으로 표현}}$$

해석:

$\sigma \nearrow$ (Noise Increase) $\longrightarrow d(x)$ flatten $\longrightarrow$ Boundary $k \nearrow$ (Wider)

높은 노이즈(σ) $\rightarrow$ 낮은 신뢰도 $\rightarrow$ 모호한 판단 경계

Part II

Active Inference — 이론의 수식적 해석 — 1조

뇌는 예측 기계이다 The Low Road

Claim: 뇌는 ‘surprise’를 최소화하는 generative model이다.


Surprise: model이 예측하지 못한 감각 입력이 들어온 정도, $-\log p(o)$

Example. Surprise 예시

사람의 체온 분포 $P(o)$ 에 대한 확률 밀도 $p(o)$ 를 가정하자.

- $-\log p(37^\circ\text{C}) = -\log 0.4 = 0.3979$
- $-\log p(40^\circ\text{C}) = -\log 0.01 = 2$

Surprise는 분포서 평균과 멀리 떨어져 있을 때 큰 값을 가진다.



Surprise의 평균과 Entropy

관측값 o 에 대한 surprise $I(o)$ 에 기댓값을 취하면 정보 엔트로피가 된다:


$$I(o) = -\log p(o)$$

$$H = \mathbb{E}[I(o)] = -\int p(o) \log p(o) \, do$$

∴ Surprise를 지속적으로 최소화 → 장기적으로 entropy가 낮게 유지

뇌는 예측 기계이다 The Low Road


Claim: 뇌는 'surprise'를 최소화하는 generative model이다.



뇌는 예측 기계이다 The Low Road

Claim: 뇌는 ‘surprise’를 최소화하는 generative model이다.

Generative Model: 세계가 어떻게 관측을 만들어내는지에 대한 확률적 설명



뇌: surprise $-\log P(y)$ 최소화 $\rightarrow P(y, x) \approx P(x)$

뇌는 예측 기계이다 The Low Road

Free Energy Principle

Goal: surprise $-\log P(y)$ 최소화 $\rightarrow P(y)$ 계산 필요

$$P(y) = \sum_x P(y, x) = \sum_x P(y|x)P(x)$$

Problem: $P(y)$ 를 직접적으로 구할 수가 없음 ($\because$ 모든 x 에 대하여)

Solution: $P(y)$ 를 구하는 문제를 최적화 문제로 변환

Idea: surprise $-\log P(y)$ 의 **상한** 최소화 $\rightarrow$ 자동적으로 surprise 최소화




뇌는 예측 기계이다 The Low Road

Variational Free Energy, $F[Q, y]$: Surprise $-\log P(y)$ 의 상한

Approximate posterior $Q(x)$ 에 대하여

$$-\log P(y) = -\log \mathbb{E}_{Q(x)} \left[\frac{P(y, x)}{Q(x)} \right] \leq -\mathbb{E}_{Q(x)} \left[\log \frac{P(y, x)}{Q(x)} \right] =: F[Q, y]$$

뇌: free energy $F[Q, y]$ 최소화 $\rightarrow Q(x) \approx P(x|y)$





뇌는 예측 기계이다 The Low Road

Active Inference


Principle: Free Energy Principle – 뇌는 free energy를 최소화하는 방향으로 작동

Active Inference: Free Energy Principle에 기반하여 수식을 해석하고, 뇌의 추론 및 의사결정 과정을 모델링하는 학문




지각: 믿음을 세상에 맞추기 / 행동: 세상을 믿음에 맞추기

Mandelbrot set
 $truth: z_{n+1} = (z_n)^2 + c$



뇌는 예측 기계이다 The Low Road

Active Inference



뇌는 예측 기계이다 The Low Road

Active Inference

Variational free energy의 식을 전개하여 새로운 의미 고찰

$$\begin{aligned} F[Q, y] &= -\mathbb{E}_{Q(x)}[\log \frac{P(y, x)}{Q(x)}] \\ &= \underbrace{-\mathbb{E}_{Q(x)}[\log P(y, x)]}_{\text{Energy}} - \underbrace{H[Q(x)]}_{\text{Entropy}} \end{aligned} \quad (1)$$

$$= \underbrace{D_{KL}[Q(x) || P(x)]}_{\text{Complexity}} - \underbrace{\mathbb{E}_{Q(x)}[\log P(y|x)]}_{\text{Accuracy}} \quad (2)$$

$$= \underbrace{D_{KL}[Q(x) || P(x|y)]}_{\text{Divergence}} - \underbrace{\log P(y)}_{\text{Evidence}} \quad (3)$$

Goal: free energy $F[Q, y]$ 최소화

생명체의 존재성과 추론 The High Road


생명체의 존재성 (Self-Evidencing)

Example. 무작정 surprise를 최소화해도 되는가?

차가운 물속에 빠진 쥐가 있다. 다음 중 surprise를 줄이는 방법은?

1. 체온을 낮추어 물과 비슷한 체온이 된다.
2. 자신의 체온을 유지한다.

무작정 surprise 최소화 → 소산적 과정 → 존재성 상실



“차가운 물, 차”



존재성



“체온을 유지해야 해”



증거 수집



“물에 있기 때문이야”



Surprise 최소화



“물 밖으로 나가짜”

생명체의 존재성과 추론 The High Road

Markov Blankets

Goal: 생명체의 존재성 modeling → 외부와 독립적인 생명체 modeling

Definition. Markov Blankets


Markov Blanket variable μ 와 x 가 주어졌을 때, blanket b 에 대하여 다음을 만족한다:

$$\mu \perp x \mid b \Leftrightarrow P(\mu, x | b) = P(\mu | b)P(x | b)$$

- x : 세상 $\perp \mu$: 생명체 $\mid b$
- $b = (u: \text{행동}, y: \text{감각})$

정보 전달:

- 세상 → 생명체: 감각
- 생명체 → 세상: 행동




설계와 데이터 분석

설계 구조 단계



1. Modeling system 정의
 - 뇌와 세계의 경계 정의
2. 가장 적절한 generative model 지정
 - model 특성: discrete/continuous, shallow/deep
3. setting up generative model
 - parameter, prior 지정
 - state/parameter update에 따른 고정, 학습 유무
4. setting up generative process
 - 실제 외부 세계 과정 정의

Action, perception
자유 에너지 함수에서
감소 방향으로 이동



Generative model

Mirza's research (discrete model)



- Data: 피험자의 도약적 안구 운동 (discrete time, state)
- 추론 방식
 - 행동 data로부터 parameter 역추론
 - 피험자의 subjective model 가정
- 역추론 결과 evidence 척도:
정보 획득 포함 model > 포함하지 않은 model
-> 인간은 정보를 얻기 위해 행동

Part III

관련 공모전 참여 — 2조

관련 공모전 참여 AI Co-Scientist Challenge

음원 위치 추정 과제

- 사례: 음원 위치 추정 과제가 있다. 실험 참가자는 스피커에서 나오는 소리를 듣고 그 위치(s)를 보고해야 하지만, 뇌는 노이즈가 섞인 측정치(x)만을 받게 된다.
- 수식 설명: 이는 베이지안 관점에서 사후 확률 평균 수식 $\mu_{post} = J + J_s J_x + J_s \mu$ 로 표현된다. 이때 x 는 감각 측정치, μ 는 소리가 정면에서 날 것이라는 사전 지식의 평균을 나타낸다. 이는 불확실한 감각 정보와 기존 지식을 각각의 정밀도(J, J_s)에 따라 가중 평균하여 최종 지각치를 결정하는 과정이다.
- 기대 자유 에너지 G를 통한 탐색(exploration) vs 이용(exploitation) 해결



Figure: AI Co-Scientist Challenge

Thank You

Q&A

BCSC 97 | Term 2 | Probabilistic Computational Neuroscience