



Probabilistic Computational Neuroscience

팀장: 윤시원 | 팀원: 곽수현, 김민선, 서효정, 이서영, 이서현(건국대), 이서현(성신여대), 임수빈

Brain and Cognitive Science Community 9th



1조: Active Inference 탐구

Abstract

Free Energy Principle(FEP)은 뇌가 예측하지 못한 값, 즉 surprise를 최소화하는 방향으로 작동한다고 주장한다. Active Inference는 Free Energy Principle에 기반하여 수식을 해석하고, 이 수식에서 창발되는 뇌의 추론 및 의사결정 과정을 모델링하는 학문이다. 본 스터디 1조는 Thomas Parr의 책을 읽고 토의하며 Active Inference에 대하여 탐구하였다.


Surprise & Free Energy

Surprise는 model이 예측하지 못한 감각 입력이 들어온 정도로 정보 이론적인 값이며 $-\log P(x)$ 로 정의된다. 이는 분포서 평균과 멀리 떨어져 있을 때 큰 값을 가지는데, 예를 들어 사람의 체온 분포에 대하여 일반적인 체온 37 °C서는 낮은 surprise 값을, 고온 40 °C서는 높은 값을 가지게 된다. Free Energy Principle은 생명체는 surprise를 줄이는 방향으로 작동하며, 이는 생존으로 이어진다고 주장한다.



Biological Implementation: Neural Message Passing

Process theory를 사용하여 위와 같은 수학적 원리가 생물학적 뇌에서 구현되는 방식을 탐구하였다. 뇌의 신경 구조와 신경 전달 물질의 역동을 variational message passing 알고리즘과 매핑했고, 신경세포의 활동 전위는 믿음을 업데이트하는 gradient descent 과정으로, 시냅스 연결 강도는 model의 매개변수로 해석된다.



Temporal Dynamics: Discrete vs. Continuous Time


Active Inference는 뇌의 실제 계산 과정을 그대로 모사하기 보단 해결하려는 문제를 설명할 수 있는 generative model을 먼저 설계하고 그 model을 통해 인지와 행동을 설명하는 top-down 방식 설계이다. 즉, 알고리즘의 적용보다는 model의 구조가 중요한 것이고, 이는 4단계 설계를 통해 구성된다:

1. System modeling: modeling할 시스템의 경계 정의
2. Form or generative model: model의 수학적 구조 결정
3. Setting up generative model: model의 변수와 확률 구조 설정
4. Setting up generative process: 실제 환경 정의

뇌의 인지 과정은 연속적인 환경 속에서도 saccade와 같은 불연속적 정보 수집 단계를 기반으로 작동하며, 각 시간 단계마다 감각 결과(o)를 통해 숨겨진 상태(s)를 역추론하고 다음 행동을 결정한다는 점에서 discrete time model이 제시되었다.

$$\underbrace{J(\pi)}_{\text{Epistemic value}} = \underbrace{H[Q(\tilde{o}|\pi)]}_{\text{Post. Pred. entropy}} - \underbrace{E_{Q(\tilde{s}|\pi)}[H[P(\tilde{o}|\tilde{s})]]}_{\text{Expected ambiguity}}$$

Epistemic value를 통해 정보 탐색의 수학적 원리를 설명할 수 있다. 단순한 보상 획득을 넘어, 탐색을 수행하는 생물학적인 동기를 정식화한 지표인 $J(\pi)$ 는 특정 행동 policy(π)이 기대되는 정보 획득량을 나타낸다.



Discrete model을 보완하기 위해 제시된 continuous time model은 감각 수용기에 영향을 미치는 물리적 변동과 신체 효과기의 연속적인 움직임을 기술할 수 있다. Discrete model과의 통합을 통해 Active Inference 이론은 감각 · 운동 · 환경 상호작용을 단일한 generative model framework 안에서 설명할 수 있게 된다.

Conclusion

본 스터디 1조는 FEP에 기반한 Active Inference에 대하여 학습하며, 뇌의 현상을 수식화하고 수식에서 창발되는 특성을 탐구하였다. 팀원이 각자 책의 부분을 나누어 발제하는 활동을 통해 이론적 토대 및 실제 적용을 탐구하였다. 추가적으로 현대 AI (LLM 등)와 Active Inference의 근본적 차이 비교·분석 및 Active Inference의 실험적 검증을 다룬 논문을 리뷰하였다. 다양한 전공으로 구성되어 각자 자신이 배운 내용에 기반한 해석을 제시하여 시야를 넓힐 수 있었다. 추가적으로 현대 AI (LLM 등)와 Active Inference의 근본적 차이 비교·분석 및 Active Inference의 실험적 검증을 다룬 논문을 리뷰를 진행하였다.

- Reference: Parr, Thomas, et al. *Active Inference: The Free Energy Principle in Mind, Brain, and Behavior*. MIT Press, 2022.



Probabilistic Computational Neuroscience

팀장: 윤시원 | 팀원:곽수현, 김민선, 서효정, 이서영, 이서현(건국대), 이서현(성신여대), 임수빈

Brain and Cognitive Science Community 9th


2조: 확률 모델링

Abstract

확률적 뇌 신경과학은 실제 관찰한 바를 확률 model로 나타내며 이로부터 새로운 지식을 얻는 것을 목표로한다. 때문에 실제 현상을 확률 model로 변환하는 과정은 필수적인데, 본 스터디 2조는 다양한 예제에 기반하여 확률 modeling하는 방법에 대하여 탐구하였다.

Bayesian Inference in Perception: From Uncertainty to Decision Making


i. Inferring Hidden States (S) from Noisy Observations (x)



우리는 세계를 직접 관찰하지 못하고 noisy observation만 얻는다. 따라서 지각의 문제는 관측을 바탕으로 세계상태를 추론하는 것이다.

- $p(s)$: prior belief
- $p(x|s)$: likelihood
- $p(s|x)$: posterior belief

ii. Same-Different Judgment




두 자극이 같은 원인에서 왔는지 또는 다른 원인인지 판단하는 문제이다. 단순 비교가 아니라 causal inference problem이다.

숨은 변수:

- C = common cause (same)
- C = independent causes (different)


iii. Visual Search



베이지안 관점에서 시각적 탐색은 관측된 감각 정보로부터 숨은 변수(hidden variable)를 추론하는 문제로 설명된다. 관찰자는 각 위치에서 얻은 감각 정보를 바탕으로 목표가 존재할 가능성을 계산하고 가장 가능성이 높은 위치를 선택한다.

Probabilistic Framework of Human Cognition: Perception, Learning, and Decision

i. Bayesian Inference under Measurement Noise




[Figure] 사전 분포와 우도 함수를 곱해 사후 분포가 형성되고 최적 추정치가 결정되는 원리를 보여주는 그래프

인간은 노이즈 섞인 측정치(x)와 사전 지식(μ)을 결합하여 판단한다. 이는 베이지안 관점에서 다음과 같이 표현된다:

$$\text{사후 확률 평균 수식: } \mu_{\text{post}} = \frac{Jx + Js}{J + Js}$$

이는 불확실한 감각 정보와 기존의 지식을 각 정보의 정밀도 (J, J_s)에 따라가중 평균함으로써 최정확적인 지각 추정치의 불확실성을 최소화함을 나타내는 과정이다.

ii. Learning as Inference




[Figure] 새로운 관찰 데이터가 추가됨에 따라 사후 확률 분포가 점차 좁아지며 실제 값에 가까워지는 '믿음의 진화'를 보여주는 그래프

인간은 반복되는 관찰 데이터(x_t)와 이전의 기대치(r_{t-1})를 결합하여 학습한다. 이는 베이지안 관점에서 다음과 같이 표현된다:

$$\text{업데이트 수식: } \hat{r}_t = \hat{r}_{t-1} + \frac{1}{t+2} (x_t - \hat{r}_{t-1})$$

이는 실제 관찰 결과와 이전 기대치 사이의 차이인 '예측 오차'를 바탕으로 세상의 규칙(파라미터)에 대한 믿음을 점진적으로 수정해 나감을 나타내는 과정이다.

iii. Discrimination and Detection



[Figure] 두 가설의 노이즈 분포와 그 사이에서 결정 경계가 설정되어 정답과 오답 확률이 결정되는 방식을 보여주는 그래프


인간은 불확실한 감각 신호(x)와 가설의 발생 빈도(사전 확률)를 결합하여 결정한다. 액스레이 사진을 보고 종양의 유무를 판단하는 탐지 사례가 있으며, 이는 베이지안 관점에서 다음과 같이 표현된다:

$$\text{최적 결정 기준 수식: } k_{\text{MAP}} = s - \frac{\sigma^2}{\Delta s} \log \frac{p(s_+)}{p(s_-)}$$

이때 σ 는 감각 노이즈의 크기를 나타내며, $p(s_-)$, $p(s_+)$ 는 각 가설이 발생할 사전 확률의 비율을 나타낸다. 이는 불확실한 감각 신호와 가설의 위 구성을 모두 고려해, 오류를 최소화하고 정확도를 극대화할 수 있는 최적의 의사결정 경계선을 설정함을 나타내는 과정이다.

Bayesian Binary Classification and Marginalization

i. Response Distribution & Gaussian Distribution




베이지안 지각 모델에서는 동일한 자극이 반복되더라도 measurement noise 때문에 측정값 x 가 변하며, likelihood, posterior, 그리고 추정치 역시 달라진다.

Gaussian 가정에서의 응답 분포는 다음과 같다:

$$p(s_{PM}|s) = \mathcal{N}\left(s_{PM}; \frac{Js + J_s \mu}{J + J_s}, \frac{1}{J + J_s}\right)$$

ii. Binary Classification and Marginalization




- Binary Classification**
측정값 x 를 이용해 클래스 C 를 추론 사후 확률($p(C|x)$)이 높은 클래스를 선택

- Marginalization**
결합 확률 분포에서 관심 없는 변수 (nuisance variable)를 통합하여 제거


$$p(x|C) = \int p(x|s)p(s|C)ds$$

iii. Top-level Nuisance Variables and Ambiguity



[Color Perception]

두 중앙 시각형의 retinal intensity가 같아도, 주변 맥락이 조명이 다르다고 암시하면 shade posterior로 인해 서로 다른 밝기로 지각된다




[object recognition]
이미지 촬영 각도 θ 는 nuisance variable이다

$$p(s|C) = \int p(s|C, \theta)p(\theta|C)d\theta$$

Optimal Integration and Decision-Making under Perceptual Uncertainty: A Bayesian Framework

i. Sensory Evidence and Bayesian Perception



감각(sensation)과 지각(percept)은 다르다. 관찰(observation)은 추론의 입력이며, 지각은 뇌가 베이지안 추론을 통해 형성한 최선의 가설이다. 동일한 관찰이라도 prior와 likelihood에 따라 posterior가 달라질 수 있다.


예를 들어 반짝이는 바닥(shiny) 단서를 통해 바닥이 젖었는지(wet)를 추론하거나, 시간이 지나며 prior가 변하는 수하물 컨베이어 벨트 사례는 이러한 지각 추론 과정을 보여준다.

ii. Cue Combination and Evidence Accumulation

이는 하나의 감각이 아니라 여러 sensory cues를 통합해 지각을 형성한다. 각 단서는 Precision $J = 1/\sigma^2$ 에 비례하는 가중치를 가지며, 이를 통해 불확실성을 최소화한다. 안개 속에서 공의 위치를 추정할 때 시각 노이즈가 증가하면 정각 정보에 더 의존하게 되며, 시청각 정보 충돌에서 나타나는 McGurk effect 역시 이러한 cue 통합의 사례이다.

$$\mu_{\text{post}} = \frac{J_1 x_{\text{obs},1} + J_2 x_{\text{obs},2}}{J_1 + J_2}$$

iii. Inference in a Changing World



변화하는 환경에서 되는 Hidden Markov Model(HMM)을 통해 상태를 추적한다. Markov property에 따라 현재 상태는 직전 상태에 의존하며, 이전 믿음을 기반으로 예측(prediction)하고 새로운 관찰로 업데이트(update)하는 재귀적 추론이 이루어진다.

iv. Combining Inference with Utility

행동 선택은 확률뿐 아니라 결과의 보상과 비용을 고려한 Expected Utility(EU)를 최대화하는 방향으로 이루어진다. 특히 비대칭 손실(asymmetric loss) 환경에서는 위험을 피하는 방향으로 판단이 편향될 수 있다. 예를 들어 비 확률이 낮아도 컷는 비용을 고려해 우산을 챙기는 것이 optimal action이다.

Reference

- Ma, Wei Ji, et al. *Bayesian Models of Perception and Action: An Introduction*. MIT Press, 2023.