



Chapter 2. Using Bayes' Rule

0. 이 챕터의 목적

Chapter 2의 목표는 단순히 Bayes' rule 공식을 소개하는 것이 아니다.

이 장의 핵심은 다음 질문에 답하는 것이다.

“관측(observation)을 보았을 때, 우리는 세계(world)에 대해 어떻게 믿음을 업데이트 해야 하는가?”

이를 위해 저자들은:

- Bayesian modeling의 절차
- prior, likelihood, posterior의 역할 분담
- 사람들이 흔히 저지르는 확률적 오류
- Bayesian inference가 지각과 결정으로 이어지는 방식을 단계적으로 설명한다.

1. Bayesian Modeling의 전체 구조 (2.1)

Bayesian 모델은 항상 정해진 순서를 따른다.

Step 1. Generative Model (생성 모델)

- 세계가 어떻게 관측을 만들어내는지에 대한 확률적 설명
- 반드시 포함되는 변수:
 - 세계 상태(world state)
 - 관측(observation)
- 핵심 질문:

“만약 세계가 이 상태라면, 이런 관측이 얼마나 자주 나타나는가?”

👉 Generative model은 관측 → 세계가 아니라

세계 → 관측 방향이다.

Step 2a. Inference (추론)

- 관측이 주어졌을 때:

┆ “이 관측을 만들어냈을 가능성이 가장 높은 World State 은 무엇인가?”

여기서 Bayes' rule이 등장한다.

$$p(H \mid obs) = \frac{p(obs \mid H)p(H)}{p(obs)}$$

- $p(H)$: prior (관측 이전의 믿음)
- $p(obs \mid H)$: likelihood (가설이 맞을 때 관측이 나올 가능성)
- $p(H \mid obs)$: posterior (관측 이후의 믿음)

👉 Inference는 generative model을 '거꾸로' 사용하는 과정이다.

Step 2b. Read-out (지각·결정으로의 변환)

- posterior는 확률 분포일 뿐, 그 자체로 행동이나 지각은 아니다.
- posterior → percept / decision으로 바꾸는 규칙이 필요하다.

가장 단순한 read-out:

- **MAP (Maximum A Posteriori)**
→ posterior가 가장 큰 가설을 선택

중요한 구분:

- **Observation:** 감각 입력
 - **Percept:** 추론의 결과
 - **Decision:** 비용·보상이 개입된 선택
-

2. Prior, Likelihood, Posterior의 역할 분담

Prior

- 관측 이전에 이미 가지고 있던 기대
- 세계에서 각 상태가 얼마나 자주 일어나는지에 대한 믿음
- base rate, prevalence와 연결됨

👉 prior는 "편견"이 아니라 **정보의 축적 결과**다.

Likelihood

- 가설이 맞다고 가정했을 때, 이 관측이 얼마나 자연스러운가
- **가설의 함수**이지, 관측의 확률이 아님

주의점:

- likelihood들은 **합이 1일 필요가 없다**
- "likelihood of the observation"이라는 표현은 잘못

👉 likelihood는 **증거가 가설을 얼마나 지지하는지**를 말해준다.

Protoposterior

- likelihood × prior
 - 정규화되기 전의 값
 - 직관적으로는:
| "이 가설이 맞고, 동시에 이 관측이 나올 확률"
-

Posterior

- protoposterior를 전체 합으로 나눈 값
 - 반드시 1로 정규화됨
 - 관측 이후의 최종 믿음
-

3. Likelihood ratio vs Prior ratio (핵심 통찰)

Posterior의 비율은 다음처럼 쓸 수 있다.

$$\frac{Posterior(H_1)}{Posterior(H_2)} = \frac{Likelihood(H_1)}{Likelihood(H_2)} \times \frac{Prior(H_1)}{Prior(H_2)}$$

이 식이 말하는 바는 명확하다.

- **Likelihood ratio:** 관측이 어느 가설을 더 지지하는가
- **Prior ratio:** 관측 이전에 어느 가설이 더 유리했는가

👉 관측이 아무리 강해 보여도,
prior가 극단적으로 불리하면 결론은 쉽게 바뀌지 않는다.

4. Areal Representation (면적 직관)

Bayes' rule은 면적으로 이해할 수 있다.

- 전체 사각형: 모든 경우
- 부분 사각형: 각 가설의 prior
- 색칠된 영역: 특정 관측

Posterior란:

┃ “관측이 일어난 영역 중에서, 특정 가설이 차지하는 비율”

👉 Bayes는 복잡한 공식이 아니라
조건이 바뀐 뒤의 비율 계산이다.

5. Prosecutor's Fallacy (조건부 확률의 비대칭성)

핵심 오류:

$$p(A | B) \neq p(B | A)$$

사람들이 흔히 하는 착각:

- “이 증거는 매우 희귀하다”
- → “그럼 피의자가 범인일 확률도 매우 높다”

하지만 Bayes 관점에서는:

- 증거의 희귀성 = likelihood
- 범인의 희귀성 = prior

👉 likelihood만 보고 posterior를 판단하면 심각한 오류가 발생한다.

6. Changing Prior: 시간에 따라 변하는 기대 (Luggage 예제)

같은 관측이라도:

- 언제 보느냐
- 이전에 무엇을 경험했느냐
에 따라 posterior는 달라진다.

핵심 메시지:

- $\text{perception} \neq \text{likelihood}$
- $\text{perception} = \text{likelihood} \times \text{expectation}(\text{prior})$

👉 prior는 고정된 값이 아니라

경험과 맥락에 따라 계속 업데이트된다.

7. Flat Prior에서도 Bayesian Inference는 작동한다 (Gestalt 예제)

흔한 오해:

| “Bayesian 모델은 항상 prior가 중요하다”

Gestalt 예제에서는:

- prior는 동일(균등)
- likelihood 구조의 차이만으로 posterior가 결정됨

👉 어떤 문제에서는:

- prior보다 **likelihood가 지배적**
- Bayesian inference = “prior 만능”이 아님

8. Bayesian Inference와 Optimality (2.7)

Bayesian inference는 종종 **최적 행동(optimal behavior)**과 연결된다.

- posterior는 “주어진 정보로 알 수 있는 전부”
- 최적 전략은 posterior를 기반으로 결정됨

하지만 중요한 caveat:

- 최적 행동 $\neq$ 뇌가 posterior를 명시적으로 계산
- 관측 $\rightarrow$ 반응이 Bayes 결과와 같으면

as-if Bayesian behavior라고 부른다.

9. Chapter 2 핵심 요약

- Bayesian modeling은 절차를 따른다:
 - generative model → inference → read-out
- Conditional probability는 비대칭이다.
- Posterior는 prior와 likelihood의 균형 결과다.
- Likelihood는 증거의 힘, prior는 기대를 나타낸다.
- Priors는 고정된 편견이 아니라 경험의 요약이다.
- Bayesian inference는 최적 행동의 핵심 구성 요소다.

Problem 2.5 — Bayes로 의학 검사 해석하기 (풀이)

0) 기호/조건 정리

- D: 질병이 있음
- -D: 질병이 없음
- +: 검사 양성
- -: 검사 음성
- 유병률(prevalence): $P(D) = 0.01 \rightarrow P(-D) = 0.99$
- false-alarm rate: $P(+ \mid -D) = 0.02$
- miss rate: $P(- \mid D) = 0.03 \rightarrow$ 따라서 $P(+ \mid D) = 1 - 0.03 = 0.97$

목표: 양성일 때 실제로 병일 확률 :

$$P(D \mid +)$$

(a) Quick guess (직관 추정)

- 보통은 “검사 정확도가 높으니 양성이면 거의 병이다”라고 추정하기 쉽다.

- 하지만 유병률이 낮으면(1%) **가짜 양성**이 생각보다 많이 쌓인다 → 실제 확률이 크게 낮아질 수 있다.

(b) $P(D | +)$ 계산

1) Bayes 공식

$$P(D | +) = \frac{P(+ | D)P(D)}{P(+)}$$

여기서 $P(+)$ 는 전확률공식으로:

$$P(+)=P(+|D)P(D)+P(+|\neg D)P(\neg D)$$

2) 값 대입

- 분자:

$$P(+|D)P(D)=0.97\times0.01=0.0097$$

- 분모:

$$P(+)=0.97\times0.01+0.02\times0.99=0.0097+0.0198=0.0295$$

따라서

$$P(D|+)=\frac{0.0097}{0.0295}\approx0.3288$$

 결론:

$$P(D|+)\approx0.329\quad(\text{약 }32.9\%)$$

3) 해석(왜 33%밖에 안 되나?)

- 유병률 1%라서 “병 없는 사람”이 압도적으로 많다.
- 그 중 2%가 가짜 양성을 내면, **가짜 양성 수가 꽤 커진다.**
- 그래서 양성 집단 안에는 “진짜 양성”보다 “가짜 양성”이 많이 섞일 수 있다.

(c) ‘검사 받으러 온 사람’ 조건 T 추가

문제의 추가 정보:

- 질병이 있는 사람이 검사하러 올 가능성이 더 큼
- 비율 가정:

$$\frac{P(T | D)}{P(T | \neg D)} = 5$$

목표: 검사받은 집단에서 양성일 때 병일 확률

$$P(D | +, T)$$

Step 1) 먼저 검사받은 집단에서의 유병률 $P(D | T)$ 구하기 (prior 업데이트)

$$P(D | T) = \frac{P(T | D)P(D)}{P(T | D)P(D) + P(T | \neg D)P(\neg D)}$$

비율만 주어졌으니 $P(T | \neg D) = a$, $P(T | D) = 5a$ 로 두면 a 는 약분됨:

$$P(D | T) = \frac{5 \cdot 0.01}{5 \cdot 0.01 + 1 \cdot 0.99} = \frac{0.05}{1.04} \approx 0.04808$$

따라서

$$P(\neg D | T) = 1 - 0.04808 = 0.95192$$

✅ 검사받은 집단에서 유병률이 1% → 약 4.81%로 상승

Step 2) 이제 $P(D | +, T)$ 계산

검사 성능이 T와 무관하다고 보고:

$$P(+ | D, T) = P(+ | D) = 0.97$$

$$P(+ | \neg D, T) = P(+ | \neg D) = 0.02$$

Bayes(조건 포함) 적용 (prior이 갱신되었음):

$$P(D | +, T) = \frac{P(+ | D)P(D | T)}{P(+ | D)P(D | T) + P(+ | \neg D)P(\neg D | T)}$$

값 대입:

- 분자: $0.97 \times 0.04808 = 0.04664$
- 분모: $0.04664 + 0.02 \times 0.95192 = 0.04664 + 0.01904 = 0.06568$

$$P(D \mid +, T) = \frac{0.04664}{0.06568} \approx 0.710$$

✅ 결론:

$$P(D \mid +, T) \approx 0.71 \quad (\text{약 } 71\%)$$

(c) 해석: 왜 갑자기 71%로 올라가나?

- T는 “검사받으러 온 사람”이라는 **선별 조건**이다.
- 병이 있는 사람이 더 자주 검사받으러 오면, 그 집단의 유병률(prior)이 올라간다.
- prior가 올라가면 같은 검사 결과(양성)라도 posterior가 크게 상승한다.

👉 한 줄 요약:

| 검사 정확도만이 아니라, ‘검사 대상 집단의 유병률(prior)’이 결과 해석을 좌우한다.

✅ Problem 2.6 — 왜 likelihood는 합이 1이 될 필요가 없나?

문제

| likelihood는 왜 합이 1이 될 필요가 없는가? 반면 prior와 posterior는 왜 합이 1이어야 하는가?

1) 결론 한 줄

- prior/posterior는 '가설 H'에 대한 **확률분포**이므로 $\sum H = 1$ 이어야 한다.
- likelihood $p(obs \mid H)$ 는 '가설 H'에 대한 **분포가 아니다**. 관측 obs를 고정한 채 각 H에서의 값만 비교하므로 $\sum H = 1$ 일 필요가 없다.

2) prior와 posterior는 왜 합이 1이어야 하나?

(1) prior $p(H)$

- H 는 가능한 가설들의 집합(서로 배반, 전체를 다 덮음)
- “관측 전에 내가 가설을 어떻게 믿고 있는가”를 나타내는 **확률분포**

따라서 가능한 모든 가설에 대해:

$$\sum_H p(H) = 1$$

(2) posterior $p(H \mid \text{obs})$

- 관측을 본 후에 가설에 대한 믿음을 업데이트한 **확률분포**
- 역시 H 의 가능한 값들이 전체를 이루므로:

$$\sum_H p(H \mid \text{obs}) = 1$$

👉 정리: prior와 posterior는 “가설을 어떤 비율로 믿는지”라서 반드시 1로 정규화되어야 한다.

3) likelihood는 왜 합이 1이 될 필요가 없나?

(1) likelihood의 정의

$$p(\text{obs} \mid H)$$

뜻:

“가설 H 가 참일 때, 이런 관측 obs 가 나올 확률”

여기서 핵심은:

- 확률분포가 되는 대상은 **H 가 아니라 obs** 쪽이다.

즉, H 를 고정하면

$$\sum_{\text{obs}} p(\text{obs} \mid H) = 1$$

이건 맞다. (관측 가능한 값들을 전부 더하면 1)

하지만 문제는 우리가 보통 likelihood를 쓸 때는:

- obs 는 이미 관측된 값으로 **고정**
- H 를 바꿔가며 $p(\text{obs} \mid H)$ 를 계산해서 비교

그래서 $p(\text{obs} \mid H)$ 들을 H 에 대해 더한 값은

어떤 의미 있는 “분포”가 아니다.

👉 likelihood는 “가설의 분포”가 아니라 “가설별 점수”처럼 쓰이는 값이다.

4) 직관적인 예시

예: 바닥이 shiny일 때

- $p(\text{shiny} \mid \text{wet}) = 0.8$
- $p(\text{shiny} \mid \text{dry}) = 0.4$

이 둘을 더하면 1.2인데 전혀 문제 없음.

왜냐하면:

- 0.8과 0.4는 “wet, dry 중 하나를 뽑을 확률”이 아니라
- “각 가설이 참일 때 shiny가 나올 확률”이기 때문

즉, likelihood를 합쳐서 1을 만들 필요가 없다.

5) Bayes에서 likelihood가 ‘정규화되어야 하는 곳’

Bayes 계산에서

$$p(H \mid \text{obs}) \propto p(\text{obs} \mid H)p(H)$$

이라고 할 때,

- $p(\text{obs} \mid H)p(H)$ 는 정규화 전 값(**protoposterior**) 이고
- 이걸 H에 대해 합한 값

$$p(\text{obs}) = \sum_H p(\text{obs} \mid H)p(H)$$

으로 나누면 posterior가 됨.

👉 즉, likelihood 자체가 정규화되는 게 아니라

likelihood × prior의 결과가 posterior 형태가 되도록 정규화된다.