

2. Using Bayes' rule

모델링


1. 생성 모델 수립- 세상의 통계적 구조와 관찰데이터가 어떻게 만들어지는지 명시.(정의)
2. 추론- 특정 관찰이 주어졌을 때 세상의 상태에 대한 믿음 업데이트 후 결정을 내림

Bayes' rule

$$p(H|obs) = \frac{p(obs|H)p(H)}{p(obs)}$$


- 1번째 예시: 바닥이 젖었는지를 '반짝이는지'로 추론
- $p(H)$ 는 사전 확률(관찰 전 믿음), $p(obs|H)$ 는 가설이 맞을 때 관찰이 나올 확률, $p(H|obs)$ 는 사후 확률(관찰 후 믿음)
- 사전 확률(Prior): 경험상 바닥이 젖어 있을 확률은 10%($p(wet)=0.1$), 말라 있을 확률은 90%($p(dry)=0.9$)
- 조건부 확률: 젖은 바닥이 반짝일 확률은 80%, 마른 바닥이 반짝일 확률은 40%라고 가정

(A) Generative model



원인-> 결과

(B) Inference



결과-> 원인

관찰자 내부 모델(생각)과 실제 세상의 통계가 일치한다고 가정하지만,
다를 수도 있음

계산

$$p(\text{wet})=0.1$$

$$p(\text{dry})=0.9$$

반짝임 가능성

$$\text{Likelihood}(\text{wet}) = p(\text{shiny}|\text{wet}) = 0.8$$

$$\text{Likelihood}(\text{dry}) = p(\text{shiny}|\text{dry}) = 0.4$$

프로토 사후확률(Protoposterior)

1. 젖고 반짝: $0.1 \times 0.8 = 0.08$


2. 마르고 반짝: $0.9 \times 0.4 = 0.36$

➔ 전체 바닥 중 0.44 (44%)가 반짝임

➔ 전체 확률로 계산하면

1. 반짝이는 것 중 젖은 바닥: $0.08 / 0.44 = 0.182 = 18.2\%$

2. 반짝이는 것 중 마른 바닥: $0.36 / 0.44 = 0.818 = 81.8\%$



반짝임이라는 증거가 바닥 젖음 가설에 유리했지만, 원래 마른 바닥이 압도적으로 많았기 때문에(사전확률이 높음) 여전히 “바닥이 말랐다”고 믿는게 합리적.

결론

- **MAP 추정(Maximum-a-posteriori)**: 사후 확률이 가장 높은 가설을 선택하는 방식. 여기서는 "바닥이 말랐다"고 지각하는 것
- **관찰과 지각을 혼동하면 안됨.**
- **관찰(observation)**은 추론 과정의 입력이고(반짝임)
- **지각(percept)**은 그 출력 (바닥이 말랐다는 결론).
- 조건부 확률은 대칭적이지 않음. 일반적으로 $p(A | B) \neq p(B | A)$
- $p(shiny | wet) = 0.8$ 이지만, $p(wet | shiny) = 0.182$ 임을 확인
- 비용을 고려하면, 확률이 낮더라도 실수했을 때의 위험(젖은 바닥에서 넘어짐)이 크다면 조심하기로 결정할 수 있음.

몇 가지 예시_ 검사의 오류

- $p(A | B)$ 와 $p(B | A)$ 를 동일시하는 실수
- $p(\text{피고가 무죄} | \text{증거}) = p(\text{증거} | \text{피고가 무죄})$ 라고 생각.
- 지문 일치 확률이 1/1000이라는 전문가 증언을 듣고, 피고인이 무죄일 확률이 1/1000이라고 주장하는 것은 틀렸음
- 도시 인구: 1,000,001명
- 사전확률:
 - $Prior(\text{무죄}) = \frac{1000000}{1000001}, Prior(\text{유죄}) = \frac{1}{1000001}$
- 가능도(지문 일치 관찰):
 - $Likelihood(\text{무죄}) = \frac{1}{1000}, Likelihood(\text{유죄}) = 1$
- Protoposterior(H) = $p(\text{obs} | H) \cdot p(H)$
- Protoposterior(유죄) = $1/1000001 \times 1$ 이고 Normalization 하면 1/1001

검사의 오류_결론

- 지문이 일치해도 무작위로 1000명 중 1명은 우연히 맞을 수 있음.
- 도시엔 무죄자가 1,000,000명-그중 약 1000명이 우연히 일치할 것.
- 진짜 범인은 1명-따라서 일치한 1001명 중 범인은 1명, 무죄는 1000명.
- 결론: $p(\text{유죄}|\text{지문 일치})=1/1001$, 거의 무죄일 가능성이 큼.

몇 가지 예시_

- 수하물 컨베이어 벨트 예시
- 게슈탈트 지각

베이지안 모델링과 최적성 요약

1. 최적성(Optimality)과 목적 함수(Objective Function)

- **최적성**을 논하려면 반드시 **목적 함수**를 정의해야 함.
 - 지각(perception)에서는 → 정확도(accuracy), 오차(error)
 - 의사결정에서는 → 보상(reward), 비용(cost)
- 예: 풀숲에 사자가 있을 확률이 10%라도, 사자가 실제로 있으면 위험이 크므로 떠나는 것이 최적.

베이지안 모델링과 최적성 요약

2. 사후확률(Posteriors)의 역할

- 사후확률 계산은 항상 최적 전략 도출 과정의 일부.
- 사후확률은 “관찰을 바탕으로 세계 상태에 대해 알 수 있는 모든 것”을 나타냄.

3. 모델 불일치(Model Mismatch)

- 잘못된 생성 모델(generative model) 을 사용하면 행동은 최적이지 않음.
- 즉, 뇌가 실제 세계의 통계와 다른 내부 모델을 쓰면 비최적 행동 발생.

베이지안 모델링과 최적성 요약

4. 진화와 베이지안 모델링의 동기

- 진화를 통해 오래된 뇌 기능(지각, 운동)은 최적화되었을 가능성이 큼.
- 따라서 이런 영역에서는 최적에 가까운 행동이 나타날 수 있음.
- 하지만 반드시 진화론적 최적화를 받아들여야 베이지안 모델링을 정당화x
- 베이지안 모델은 출발점으로서, 이후 비최적적(suboptimal) 모델을 구축하는 데도 활용 가능.

5. "as-if Bayesian" 행동

- 최적 행동이 뇌가 실제로 사전확률, 가능도, 사후확률을 표현한다는 뜻은 아님.
- 단지 관찰 → 반응 매핑이 베이지안 규칙을 따른 것처럼 보일 수 있음.
- 이를 "as-if Bayesian" 행동이라고 부름.
- 실제로 뇌가 확률 분포를 표현하는지 입증하는 것은 더 복잡하며, 후속 장에서 논의됨.

발제

- 우리 모두가 같은 세상을 보고 있는가?
 - 망막에 맺히는 이미지는 하나지만 뇌는 조명, 물체의 색, 사전 경험 등을 조합해 수만가지 해석을 내놓음(세팅된 사전확률이 다름)
 - 두 사람이 같은 물체를 보고 다르게 느낀다면 누구의 지각이 정답인가?
- > 객관적인 세상이 존재하지 않고 각자의 뇌가 계산해낸 가장 그럴듯한 환상만 존재