

Bayesian Models of Perception and Action

Chapter 4 : The Response Distribution

곽수현

요약

사전확률(Prior)과 가능도(Likelihood)를 결합해,
베이지안 모델이 인간의 지각 과제의 응답을 예측하는 방법을 다룬다.

핵심 목표: 주어진 자극 s 에 대해 가능한 응답 $\hat{s}$ 의 확률을 예측
=> 응답 분포 (response distribution).


4.1 Inherited variability

- 자극 s 가 고정되어도 x_{obs} 는 시행(trial)마다 달라지는 확률변수이다.
- 일단 x_{obs} 가 결정되면, 베이지안 계산(가능도, 사후 확률, PME 계산)은 정해진 공식에 따라 기계적으로(확정적으로) 이루어진다.

응답 분포의 변동성(variability)은 측정치(x_{obs})의 변동성으로부터 **상속**된다.

= Inherited variability

Figure 4.1: 변동성의 전파



x_{obs} 의 변동이 likelihood/posterior/PME를 시행마다 바꾸는 구조

4.2 Response distribution (Gaussian case)

가정: stimulus $\sim$ Gaussian, measurement noise $\sim$ Gaussian

응답: $\hat{s}_{PM} = \mu_{post}$ (posterior mean estimate)

목표: $p(\hat{s}_{PM} | s)$ 의 평균/분산 도출

Posterior mean (PME)

$$\mu_{\text{post}} = \frac{Jx_{\text{obs}} + J_s\mu}{J + J_s} \quad \text{where } J = \frac{1}{\sigma^2} \text{ and } J_s = \frac{1}{\sigma_s^2}.$$

관찰자의 응답(response) 측정 정밀도 사전 정밀도

측정치 x_{obs} 가 참 자극 s 가 주어졌을 때 평균 s 와 분산 σ^2 을 갖는 가우시안 분포를 따르므로,
자극 추정치 $\hat{s}_{PM}$ 도 **가우시안 분포**를 따른다

Response distribution의 평균/분산

properties of linear combinations of random variables (see **Box 4.1** and **Exercise 4.1**) to show that when the true stimulus is s , the stimulus estimate $\hat{s}_{\text{PM}}$ follows a Gaussian distribution with mean

$$\mathbb{E}[\hat{s}_{\text{PM}}|s] = \frac{Js + J_s\mu}{J + J_s} \quad (4.3)$$

and variance

$$\text{Var}[\hat{s}_{\text{PM}}|s] = \frac{J}{(J + J_s)^2}, \quad (4.4)$$

or, using the shorthand notation for Gaussian distributions (see Eq. (3.3))

$$p(\hat{s}_{\text{PM}}|s) = \mathcal{N}\left(\hat{s}_{\text{PM}}; \frac{Js + J_s\mu}{J + J_s}, \frac{J}{(J + J_s)^2}\right). \quad (4.5)$$

Box 4.1: 확률 변수의 선형 조합 성질

Box 4.1 — Properties of linear combinations of random variables. In Bayesian models, we often encounter random variables that are weighted sums of other random variables. The following properties are useful:

1. **General:** If a random variable X has mean μ and variance σ^2 , and a and b are constants, then the random variable $aX + b$ has mean $a\mu + b$ and variance $a^2\sigma^2$.
2. **General:** If random variables X and Y are independent and have means μ_X and μ_Y , and variances σ_X^2 and σ_Y^2 , respectively, then the random variable $X + Y$ has mean $\mu_X + \mu_Y$ and variance $\sigma_X^2 + \sigma_Y^2$.
3. **Specific to Gaussian distributions:** If a random variable X follows a Gaussian distribution, then $aX + b$ also follows a Gaussian distribution.
4. **Specific to Gaussian distributions:** If random variables X and Y are independent and each follow a Gaussian distribution, then $X + Y$ also follows a Gaussian distributions.

- X 의 선형변환 $aX+b$:

평균 $a\mu+b$, 분산 $a^2\sigma^2$

- 가우시안은 선형변환 후에도 가우시안

X, Y 가 독립적이며 각각 가우시안 분포를 따를 때,

$X+Y$ 도 가우시안 분포를 따른다.


4.3 Belief vs Response distributions

	Mean	Variance
Step 1: Generative model	Stimulus distribution, $p(s)$ μ Measurement distribution, $p(x s)$ s	σ_s^2 σ^2
Step 2: Inference	Prior distribution, $p(s)$ μ Likelihood function $\mathcal{L}(s_{\text{hyp}}; x_{\text{obs}}) = p(x_{\text{obs}} s_{\text{hyp}})$ x_{obs} Posterior distribution $p(s_{\text{hyp}} x_{\text{obs}})$ $\hat{s}_{\text{PM}} = \frac{Jx_{\text{obs}} + J_s\mu}{J + J_s}$	σ_s^2 σ^2 $\frac{1}{J + J_s}$
Step 3: Response distribution	Response distribution, $p(\hat{s} s)$ $\mathbb{E}[\hat{s}_{\text{PM}} s] = \frac{Js + J_s\mu}{J + J_s}$	$\frac{J}{(J + J_s)^2}$

	Belief distributions (prior, likelihood, posterior)	response distribution
Bayesian modeling step	Step 2 (inference)	Step 3 (response distribution)
Nature of distributions (see Box 3.4)	subjective (degrees of belief)	objective (probabilities of occurrence)
Point of view of	the observer (decision-maker)	the experimenter
Horizontal axis	hypothesized world state	estimate of world state
Is realized	on any single trial	across many trials
Exclusive to Bayesian models	yes	no

- Belief(prior/likelihood/posterior): 관찰자 내부 신념(주관적)
- Response distribution: 반복 시행에서 관측되는 행동 통계(객관적)

Figure 4.2: 노이즈 수준과 표준편차



$\sigma \uparrow$: posterior SD는 prior SD로 수렴 / response SD는 충분히 크면 0으로 감소

PME의 분산 : 주어진 시행에서 관찰자의 불확실성

$$Var(\hat{s}_{PM}|s) = \frac{J}{(J + J_s)^2}$$

사후 분포의 분산: 실험자가 측정하는 행동의 변동성

$$\sigma_{post}^2 = \frac{1}{J + J_s}$$

=> posterior variance(불확실성)와
response variance(행동 변동성)는 개념이 다르다.

4.4 Maximum-likelihood estimation (MLE)


사후평균 대신 측정치 자체를 자극 추정치로 사용:

$$\hat{s}_{ML} = x_{obs}$$

$p(\hat{s}_{ML} | s) = p(x | s)$: MLE(s^{ML})의 분포는 측정 분포 $p(x|s)$ 와 동일

MLE (최대 가능도 추정)	PME(사후 평균 추정)
현재의 측정값 x_{obs} 만 믿고, '측정값 = 자극 s ' 라고 추정	측정값 x_{obs} 와 사전 정보 μ 를 가중 평균하여 추정
MLE는 편향이 없다. 즉, 평균적으로는 참값 s 와 일치한다.	PME는 사전 평균 μ 쪽으로 편향 된다. 평균적으로는 참값 s 와 일치하지 않는다.
노이즈(σ)가 크면 측정값이 엉뚱할 가능성이 높고, 따라서 응답의 분산이 커진다.	특히 노이즈가 클 때, 극단적인 측정값을 걸러내고 μ 근처로 응답하여 분산을 낮춘다 .

Figure 4.3: PME vs MLE



PME는 μ 쪽으로 편향(bias)되지만 분산을 줄여 MSE를 낮출 수 있음

4.5 Bias

$$\text{Bias}[\hat{s}|s] \equiv \mathbb{E}[\hat{s}|s] - s.$$

추정치 $\hat{s}$ 의 편향(Bias)은 평균 추정치와 참 자극(s) 간의 차이로 정의된다.

MLE: $E[\hat{s}_{ML}|s] = s$ 이므로, MLE의 편향은 0 (unbiased)

PME: $E[\hat{s}_{PM}|s] = \frac{Js + J_s \mu}{J + J_s}$ 이므로, Bias $\neq 0$ (prior 평균 μ 방향)

4.5 Mean Squared Error (MSE)

$$\text{MSE}[\hat{s}|s] \equiv \mathbb{E}_{\hat{s}|s}[(\hat{s} - s)^2|s]. \quad (4.8)$$

$$\text{MSE}[\hat{s}|s] = \text{Bias}[\hat{s}|s]^2 + \text{Var}[\hat{s}|s]. \quad (4.9)$$

$$\text{MSE}[\hat{s}] \equiv \mathbb{E}_{\hat{s},s}[(\hat{s} - s)^2] \quad (4.10)$$

$$= \mathbb{E}_s [\mathbb{E}_{\hat{s}|s}[(\hat{s} - s)^2|s]] \quad (4.11)$$

$$= \mathbb{E}_s [\text{MSE}[\hat{s}|s]] \quad (4.12)$$

$$\begin{aligned} \text{MSE}[\hat{s}|s] &= \left(\frac{Jx_{\text{obs}} + J_s\mu}{J + J_s} - s \right)^2 + \frac{J}{(J + J_s)^2} \\ &= \frac{J_s^2}{(J + J_s)^2} (s - \mu)^2 + \frac{J}{(J + J_s)^2}. \end{aligned}$$

Figure 4.4: Bias–variance tradeoff

(A)

Low bias, high variance



(B)

High bias, low variance, same mean squared error



bias를 감수하더라도 variance 감소가 크면 MSE가 더 작아질 수 있음

4.5.3 Inverted bias perspective

- MLE와 PME를 비교하는 관점 전환:


$\hat{s}$ 가 주어졌을 때 s 의 분포 $p(s | \hat{s})$ 를 비교

- MLE: $s | \hat{s}_{ML}$ 의 평균이 $\hat{s}_{ML}$ 에 맞지 않을 수 있음(역편향)

- PME: $s | \hat{s}_{PM}$ 의 평균이 $\hat{s}_{PM}$ 에 더 잘 정렬되는 구조

PME는 MLE보다 전반적 MSE가 낮으며, **PME가 MLE보다 더 정확한 추정치**

Figure 4.5: Inverted bias



동일 데이터에서 '응답이 주어졌을 때 진짜 자극이 어디였나'를 비교

4.9 Reflections on Bayesian models

- 베이지안 관찰자의 본질:

베이지안 관찰자는 가능한 모든 세계 상태 변수의 값을 고려하고 그 확률을 계산

규범적 모델링 (Normative Modeling):

베이지안 모델링의 가장 큰 장점 중 하나는 실험 데이터를 보기 전에 관찰자가 과제를 어떻게 수행해야 최적인지(optimal) 명시할 수 있다는 점.

베이지안 모델은 관찰자가 달성할 수 있는 가장 높은 성능의 기준(norm)을 설정

Summary

- **베이지안 모델링의 3단계:**

생성 모델 정의, PME 공식 도출, 다수 시행에 걸친 PME의 분포(응답 분포) 도출.

- **성능 척도:** 추정 성능의 척도로 **평균 제곱 오차(MSE)**를 사용했으며, 자극 조건부 MSE와 전반적 MSE를 구별

- **MSE 구성:** 자극 조건부 MSE는 Squared Bias+Variance Squared Bias+Variance의 합.

- **PME vs. MLE:**

- MLE는 편향되지 않지만, 자주 발생하는 자극에 대해 PME는 MLE보다 분산이 낮아 **전반적 MSE가 더 작다**. 따라서 PME가 전반적으로 더 우수하다.

- **분포 혼동 방지:**

- 모델링의 각 단계에서 등장하는 함수와 분포들은 (이 챕터에서는 모두 가우시안으로 보였지만) 서로 다른 개념이므로 명확하게 구별해야 한다 (Table 4.1, 4.2 참고).

- **단축 경로의 위험:**

- 3단계를 따르지 않고 응답 분포를 계산하려는 시도는 개념적 오류로 이어질 가능성이 높다.

- **PME 모델:**

- PME 모델은 최소 모델(minimal model)이며, 결정 노이즈나 응답 노이즈를 추가하여 확장할 수 있다.