

Chapter 6: Learning as Inference (추론으로서의 학습)

1. 흐름과 핵심 개념

학습(Learning)을 별개의 과정이 아닌, 베이지안 프레임워크 내에서의 '추론(Inference)'의 연장선으로 설명. 우리가 일반적으로 생각하는 학습(예: 반복을 통해 무언가를 익히는 것)은 베이지안 관점에서 보면 관찰된 데이터를 바탕으로 세계의 상태나 모델의 파라미터에 대한 확률 분포를 업데이트하는 과정.

1-1. 흐름

- (1) 매개변수 추론으로서의 학습: 고정된 값이지만 알지 못하는 파라미터를 추론하는 과정.
- (2) 재귀적 업데이트: 새로운 데이터가 들어올 때마다 지식을 갱신하는 수학적 구조.
- (3) 강화학습과의 연결: 베이지안 업데이트가 어떻게 고전적인 학습 규칙(Rescorla-Wagner)과 맞닿아 있는지 설명.
- (4) 구조적 학습: 단순히 숫자 값을 맞추는 것이 아니라, 사건들 사이의 인과 관계(Causal structure) 자체를 학습하는 과정.

2. 세부 내용 및 수식 설명

- (1) 베이지안 파라미터 추론 (Learning as Parameter Inference) 베이지안 모델에서 학습은 사후 분포(Posterior)를 계산하는 것과 같습니다. 예를 들어, 어떤 동전이 앞면이 나올 확률 θ 를 모른다고 할 때, 우리는 여러 번의 던지기 결과($x_1, x_2, \dots, x_t$)를 보고 θ 를 추론.

Generative Model: $p(x|\theta)$

Inference: $p(\theta|x_{1:t}) \propto p(x_{1:t}|\theta)p(\theta)$

- (2) 재귀적 업데이트와 학습률 (Recursive Update)

학습의 핵심 : '새로운 정보가 들어왔을 때 기존의 믿음을 어떻게 바꾸는가'

책에서 비가 올 확률(r)을 예로 들어 설명. t 번째 날까지의 데이터를 바탕으로 한 추정치 $\hat{r}_t$ 는 다음과 같은 재귀식으로 표현

$$\hat{r}_t = \hat{r}_{t-1} + \frac{1}{t+2}(x_t - \hat{r}_{t-1}) \quad 6.22$$

$x_t - \hat{r}_{t-1}$: 실제 결과(x_t)와 이전 예측($\hat{r}_{t-1}$) 사이의 차이, 예측 오차(Prediction Error)

$\frac{1}{t+2}$: 학습률(Learning Rate) 역할, 시간이 지날수록(t 가 커질수록) 분모가 커져 학습률이 낮아지는데, 이는 데이터가 쌓일수록 하나의 새로운 관찰값이 전체 믿음을 크게 흔들지 못함을 의미.

- (3) 강화학습(Reinforcement Learning)과의 연결

위의 식 (6.22)는 강화학습의 Rescorla-Wagner 규칙과 매우 유사

베이지안 모델 : '확률적 최적성'을 기반으로 학습률이 시간에 따라 변해야 함을 이론적으로

유도

강화학습 : 대개 고정된 학습률(α)을 사용

(4) 인과 구조의 학습 (Learning the Structure)

6장은 인과 관계 모델(Causal Model)의 구조 자체를 선택하는 문제도 다룸

3. 결론 및 요약

학습이 결국 "세계가 어떻게 돌아가는지에 대한 모델의 파라미터를 베이지안 방식으로 업데이트하는 것"을 강조 / 인공신경망(ANN)의 경사 하강법(Gradient Descent)과도 맥을 같이 하나 베이지안 방식은 불확실성(Uncertainty)을 직접적으로 다룬다는 점에서 강력한 차별점을 가짐.

Figure

Fig 6.1 ~ 6.3:

데이터 축적에 따른 사후 분포의 변화설명: 베이지안 학습의 가장 기초적인 원리를 보여줌. 관찰 데이터(n)가 적을 때는 분포가 넓고 평평하여 불확실성이 크나 데이터가 쌓일수록 분포가 특정 값으로 수렴하며 좁고 뽕족해지는 과정을 시각화. 이는 "경험이 쌓일수록 믿음이 확신으로 변하는 과정"을 의미


Fig 6.5:

파라미터 조합에 따른 감마 분포(Gamma Distribution)설명 : 정밀도(J_s)와 같이 음수가 될 수 없는 변수를 추론할 때 사용하는 감마 분포의 특성을 보여줌. 형상 파라미터(k)와 척도 파라미터(θ)가 변함에 따라 확률 밀도가 어떻게 이동하고 비대칭성을 띠는지 설명하며, 이것이 학습 모델의 유연성을 어떻게 결정하는지 나타냄.

Fig 6.6:

사후 분포의 재귀적 진화 (Evolution of the Posterior)설명 : 새로운 데이터가 하나씩 들어올 때마다(A), 그에 해당하는 우도 함수가 계산되고(B), 기존의 사후 분포가 새로운 데이터의 영향을 받아 실시간으로 업데이트되는 과정(C)을 보여줌. 학습이 곧 연속적인 베이지안 업데이트임을 증명하는 시각 자료.

Fig 6.8:



인과 구조 모델 (Causal Structure)설명 : 단순한 수치 학습을 넘어선 '구조적 학습'을 설명.

세 개의 변수 사이에 존재할 수 있는 다양한 인과 관계(예: 공통 원인, 인과 연쇄 등)를 도식화한 것. 뇌가 단순히 상관관계를 파악하는 것이 아니라 세계의 논리적 구조 자체를 추론한다는 점을 강조할 때 사용.

Chapter 7: Discrimination and detection

1. 흐름과 핵심 개념

'Discrimination'은 두 가지 구별되는 자극 중 하나를 선택해야 하는 상황을 다룸. 8장에서 다룰 '분류(Classification)'와 유사해 보이나 변별은 주로 매우 유사한 두 자극(예: 아주 미세하게 다른 두 선의 각도)을 구분해내는 감각적 한계와 최적의 결정 경계를 다루는 데 초점을 맞춤.

1.1. 흐름:

1. 이진 선택 모델: 두 자극 s_1, s_2 중 무엇이 제시되었는지 판단하는 과정.
2. 로그 사후 확률비(Log-posterior ratio): 결정을 내리기 위한 핵심 수학적 도구.
3. 결정 경계와 편향(Bias): 사전 확률(Prior)이 결정 경계에 미치는 영향.
4. 심리계측 함수(Psychometric function): 자극의 강도와 정답률 사이의 관계.

2. 세부 내용 및 수식 설명

(1) 변별의 베이지안 모델 (Step-by-step)

Step 1: 생성 모델: 자극 s 는 두 값(s_- 또는 s_+) 중 하나를 가짐. 측정값 x 는 노이즈가 섞인 채 관찰됨.

$$p(x|s) = \mathcal{N}(x; s, \sigma^2).$$

Step 2: 추론 (결정 규칙): 관찰자는 사후 확률비가 1보다 큰지(또는 로그 비가 0보다 큰지) 확인함.

$$d = \log \frac{p(s_+|x)}{p(s_-|x)} = \log \frac{p(x|s_+)p(s_+)}{p(x|s_-)p(s_-)}$$

(2) 로그 사후 확률비의 전가우시안 노이즈 모델을 가정할 때, 위 식은 다음과 같이 정리됨.

$$d = \frac{s_+ - s_-}{\sigma^2} \left(x - \frac{s_+ + s_-}{2} \right) + \log \frac{p(s_+)}{p(s_-)}$$

첫 번째 항: 측정값 x 가 두 자극의 중간값($\frac{s_+ + s_-}{2}$)에서 얼마나 떨어져 있는지를 노이즈의

크기(σ^2)와 자극의 차이(Δs)로 가중치를 두어 계산

두 번째 항: 자극이 나타날 사전 확률(Prior), 한쪽 자극이 더 자주 나온다는 것을 알고 있다면 결정 경계는 그쪽으로 이동함.

(3) 결정 경계 (Decision Boundary)최적의 관찰자는 $d > 0$ 일 때 s_+ 라고 대답함. 이때의 결정 경계 $x_{boundary}$ 는 다음과 같음.

$$x_{boundary} = \frac{s_+ + s_-}{2} - \frac{\sigma^2}{s_+ - s_-} \log \frac{p(s_+)}{p(s_-)}$$

사전 확률이 동일하면($p_- = p_+$), 경계는 정확히 두 자극의 중간에 위치함. s_+ 가 나올 확률이 높다면, 로그 항이 양수가 되어 경계가 왼쪽(s_- 쪽)으로 이동. 애매한 신호가 와도 s_+ 라고 대답하려는 편향(Bias) 생김.

(4) 심리계측 함수와 정답률심리계측 함수(Psychometric Function): 자극 s 의 변화에 따라 s_+ 라고 응답할 확률을 나타낸 곡선. 대개 누적 정규 분포 함수의 형태를 띰.

3. 결론 및 요약

아주 미세한 차이를 구분할 때조차 뇌가 '자극의 물리적 값'뿐만 아니라 '그 자극이 나타날 확률(기대)'을 수학적으로 정교하게 통합하고 있음을 보여줌, 특히 노이즈가 많은 상황일수록 뇌는 감각 정보보다는 사전 지식(Prior)에 더 의존하여 결정을 내리게 됨.

Figure

Fig 7.1 ~ 7.2:

변별의 생성 모델과 사후 분포설명: 두 가지 자극(s_-, s_+) 중 하나를 골라야 하는 변별 과제의 기본 세팅. 측정값(x)에 노이즈가 섞여 두 분포가 겹치는 영역이 생기는데, 이 겹치는 구간 때문에 발생하는 '판단의 모호성'을 베이저안 방식으로 어떻게 해결하는지 보여줌.

Fig 7.3:

로그 사후 확률비 (Log-posterior Ratio)설명 : 측정값 x 에 따라 한쪽 선택지가 맞을 확률이 다른 쪽보다 얼마나 더 높은지를 로그 값(d)으로 변환한 그래프. 이 선이 0이 되는 지점이 최적의 '결정 경계'가 됨, 사전 확률(Prior)이 편향되었을 때 이 직선이 위아래로 이동하며 경계 값을 어떻게 바꾸는지 설명함.

Fig 7.4:

결정 변수의 조건부 분포설명 : 실제 자극이 s_+ 일 때와 s_- 일 때, 내부적인 결정 변수 d 가 어떤 분포를 갖는지 보여줌. 두 분포의 거리가 멀수록 변별이 쉬워지며, 이는 신호 탐지 이론 (SDT)의 민감도(d') 개념과 직결됨.

Fig 7.5:

응답 빈도 매트릭스 (SDT Terminology)설명:

관찰자의 응답 결과를 4가지 유형(Hit, Miss, False Alarm, Correct Rejection)으로 분류한 표. 베이저안 모델을 통해 예측된 응답 확률이 실제 실험 데이터와 어떻게 대조되는지 정리하는 기준으로 활용됨.

Fig 7.6:

자신감의 척도 (Measures of Confidence)설명 : 로그 확률비의 절댓값이 커질수록 관찰자가 자신의 선택에 대해 느끼는 '자신감'이 어떻게 증가하는지 보여줌. "무엇인가"를 맞추는 것을 넘어, "그 답이 얼마나 확실한가"라는 주관적 확신 또한 베이지안 프레임워크로 설명될 수 있음을 보여줌.