

Chapter 8. Binary classification

1. Plan of the chapter

Bayesian model에서 중심적인 연산인 marginalization(주변화)을 기반으로 Bayesian model의 다양한 응용분야로 나아가는 기반을 마련하는 것이 목표

2. Example tasks (예시들)




Figure 8.1: A binary classification experiment. (A) Example Gabor stimulus. (B) Psychometric curve.

시각적인 과제 예시. 응답자들이 (A)와 같은 패턴을 관찰하였을 때 응답한 패턴의 방향 (반시계/시계)개수를 세어 비율 계산한 것이 (B)의 그래프, Stimulus orientation.

3. Generative model




Figure 8.2: (A) Generative model diagram. (B) Examples of mirror-imaged class-conditioned stimulus distributions.

(A)는 생성 모델의 다이어그램. 세 개의 노드로 구성되어 있음 : 클래스 C , 자극 s , 측정 x .

1) 클래스 (C)

C 의 가능한 2가지 값을 $-1, 1$ 로 지정한다. 위의 example에서는 반시계/시계가 이에 해당하고, 자극 s 의 부호와 C 의 부호가 같다.

$P(C=1) + P(C=-1) = 1$ (이진이니까 두 확률 합하면 당연 1)

2) 자극 (s)

클래스 C 가 -1 일 때와 1 일 때, 자극 s 를 서로 다른 세트에서 무작위 추출

-> 해당되는 자극 분포를 $P(s|C = -1)$ 과 $P(s|C = 1)$ 로 나타내며, **클래스 조건부 자극 분포 (CCSD)** 라고 부른다. ** 관찰자의 믿는 CCSD가 실험의 CCSD와 동일하다고 가정 **

3) 측정 (x)

$$p(x|s) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-s)^2}{2\sigma^2}}.$$

그냥 정규분포 식.

이 단계는 이전 장들과 동일함.

4. Mirror-symmetric class-conditioned stimulus distributions

Binary Classification에서 CCSDs that are mirror images of each other 가 중요함.

(예시)

1) Method of constant stimuli (s는 이산적, n개 각각 동일 확률 선택)

C=1의 경우, 값은 $s_1, s_2, \dots, s_n$ (모두 양수), C=-1인 경우 값은 거울 대칭으로 $-s_1, -s_2, \dots, -s_n$ (모두 음수)

2) Uniform distribution (s는 연속적)


C=-1일 때 구간 $[-a, 0]$ 에서 균등 분포로, C=1일 때 구간 $[0, a]$ 에서 균등 분포로 뽑는다. 여기서 a는 양수.

5. Marginalization (주변화)

주변화는 여러 변수에 대한 확률 분포를 그 중 하나에 대한 분포로 바꾸는 연산.

a, b가 이산 확률 변수이고 $p(a, b)$ 가 그들의 결합 분포라면 $p(a) = \sum_b p(a, b)$ 이렇게 표현하는 것.

[주사위 예시]



1) 문제 설정

공정한 주사위 두 개를 던진다. 각 주사위는 1부터 6까지 동일한 확률을 가진다. 우리가 구하고 싶은 것은 두 주사위의 합이 10이 될 확률이다.

2) 핵심 아이디어

합이라는 하나의 변수에 대한 확률을 구하기 위해, 첫 번째 주사위 값이라는 다른 변수에 대해 “합을 취한다”. 즉, 우리가 진짜로 알고 싶은 것은 전체 합이지만, 계산을 위해 첫 번째 주사위 값을 하나씩 고려하여 그 경우마다의 확률을 더해준다. 이것이 바로 주변화이다.

3) 구체적 의미

$$p(\text{total} = 10) = \sum_{i=1}^6 p(\text{total} = 10 | \text{first roll} = i) p(\text{first roll} = i)$$

합이 10이 되려면 가능한 조합은 (4,6), (5,5), (6,4)이다. 각각의 조합은 동일한 확률을 가지므로, 이 경우들을 모두 더하면 전체 확률을 얻을 수 있다. 결과적으로 합이 10일 확률은 3/36, 즉 1/12

가 된다.

4) 왜 이게 주변화인가

우리가 궁극적으로 관심 있는 변수는 “합”이다. 하지만 계산 과정에서는 “첫 번째 주사위 값”을 모두 고려해야 한다. 이 변수는 최종적으로 관심 대상은 아니지만, 확률을 계산하기 위해 반드시 거쳐야 하는 변수이다. 이렇게 관심 없는 변수를 모두 고려한 뒤 제거(합산)하는 과정이 marginalization이다.

6. Continuous variables

1) 기본 아이디어

앞에서는 이산 확률변수에 대해 주변화를 설명했다. 이산 변수의 경우에는 관심 없는 변수에 대해 “합”을 취했다.

하지만 주변화해야 할 변수가 연속 변수인 경우에는, 합 대신 적분을 사용한다.

2) 연속 변수에서의 주변화 정의

두 연속 확률변수 a, b 의 결합분포가 주어졌다고 하자. 우리가 a 의 주변분포를 구하고 싶다면, b 에 대해 적분한다.

$$p(a) = \int p(a, b) db \quad (8.7)$$

$$= \int p(a|b)p(b)db. \quad (8.8)$$

이 식은 “결합분포에서 b 를 제거한다”는 가장 기본적인 주변화 공식

3) 가우시안 예시

책에서는 연속 변수의 예시로 가우시안 분포를 든다. 먼저 a 와 b 가 각각 가우시안 분포를 따른다고 가정한다.

$$p(a) = \mathcal{N}(a; \mu_a, \sigma_a^2);$$

$$p(b) = \mathcal{N}(b; \mu_b, \sigma_b^2).$$

이제 새로운 변수 $c=a+b$ 라고 두면, c 의 분포를 구하기 위해 역시 적분(주변화)을 수행한다.

그 결과 $p(c) = \mathcal{N}(c; \mu_a + \mu_b, \sigma_a^2 + \sigma_b^2)$. 식을 얻는다.

즉, 평균은 두 평균의 합, 분산은 두 분산의 합이 된다.

7. Conditional marginalization

1) 기본 아이디어

지금까지는 변수 a 의 주변분포 $p(a)$ 를 구하기 위해 다른 변수에 대해 합/적분을 취했다. 그런데 실제 Bayesian 문제에서는 대부분 ‘조건이 붙은 상태’에서 주변화를 해야 함. 방식은 전과 동일.

2) 조건부 주변화의 일반 형태

조건이 붙어도 원리는 바뀌지 않는다. 결합확률을 이용해 다시 쓰면, $p(a|c)$ 는 b 에 대한 합으로 표현할 수 있다.

$$p(a|c) = \sum_b p(a, b|c) = \sum_b p(a|b, c)p(b|c)$$

-> c 가 주어진 상태에서, b 가 취할 수 있는 모든 경우를 고려한다. 각 경우에서의 조건부 확률과

그 경우가 발생할 확률을 곱한 뒤, 전부 더한다. 즉, “조건이 붙은 total probability law”.
조건이 붙어도 주변화의 구조는 동일하며, 숨겨진 변수나 nuisance variable을 반드시 포함해 계산해야 한다.

8. Using the generative model

1) 기본 구조

이제 binary classification의 generative model을 다시 본다. 구조는 $C \rightarrow s \rightarrow x$ 이다. 클래스 C 가 자극 s 를 생성하고, 자극 s 가 측정값 x 를 생성한다.

x 가 C 에 직접적으로 의존하는 것 아님. s 를 통해 간접적으로 의존한다는 것

2) 목표

우리가 실제로 필요한 것은 $p(x|C)$ 이다. 왜냐하면 이후에 Bayes rule을 사용해 $p(C|x)$ 를 구하려면 likelihood $p(x|C)$ 가 필요하기 때문이다. 그런데 모델 구조상 x 는 s 에 의해 생성되므로, s 를 제거하지 않으면 $p(x|C)$ 를 바로 쓸 수 없다.

3) 식

**** 이산 s 의 경우 ****

s 에 대해 주변화를 수행한다. 즉, $p(x|C)$ 는 s 에 대해 합을 취해 계산한다.

$$\text{when } s \text{ is discrete: } p(x|C) = \sum_{i=1}^n p(x|s_i, C) p(s_i|C); \quad (8.15) \quad \text{모}$$

델 구조상 x 는 s 가 주어지면 C 와 독립이므로 $p(x|s, C)$ 는 $p(x|s)$ 로 단순화된다.

$$\text{when } s \text{ is discrete: } p(x|C) = \sum_{i=1}^n p(x|s_i) p(s_i|C); \quad (8.17)$$

결과적으로 $p(x|C)$ 는 “각 s 에서의 측정 분포 $p(x|s)$ ”와 “클래스 조건부 자극 분포 $p(s|C)$ ”를 곱한 뒤, s 에 대해 모두 더한 형태

**** 연속 s 의 경우 ****

s 가 연속 변수라면 합 대신 적분을 사용한다. 구조는 완전히 동일하다.

$$\text{when } s \text{ is continuous: } p(x|C) = \int p(x|s, C) p(s|C) ds. \quad (8.16)$$

$$\text{when } s \text{ is continuous: } p(x|C) = \int p(x|s) p(s|C) ds. \quad (8.18)$$

9. Inference

1) 목표

우리가 실제로 관찰하는 것은 measurement x 이고, 우리가 알고 싶은 것은 class C . 즉, 우리가 구하고 싶은 것은 $p(C|x)$. 이 과정이 바로 inference.

2) Bayes rule 적용

$$d \equiv \log \frac{p(C=1|x)}{p(C=-1|x)} \quad (8.19)$$

Inference는 Bayes rule을 직접 적용하는 과정이다.

이 구조만 기억하면 된다 posterior = likelihood × prior / evidence.

3) evidence(정규화항)의 구조

$$= \log \frac{p(C=1)}{p(C=-1)} + \log \frac{p(x|C=1)}{p(x|C=-1)}. \quad (8.20)$$

$p(x)$ 는 모든 클래스에 대해 $p(x|C)$ $p(C)$ 를 더한 것. -> 여기서 또 한 번 주변화가 일어난다.

4) Decision rule (MAP)

$$\mathcal{L}(C=1;x) \equiv p(x|C=1) = \int p(x|s)p(s|C=1)ds; \quad (8.21)$$

posterior가 더 큰 클래스를 선택한다. binary classification에서는 $p(C=1|x)$ 와 $p(C=-1|x)$ 를 비교한다.

5) Posterior ratio

$$\mathcal{L}(C=-1;x) \equiv p(x|C=-1) = \int p(x|s)p(s|C=-1)ds. \quad (8.22)$$

posterior ratio > 1 이면 $C=1$ 선택. log를 취하면 계산이 더 단순해진다.

$$\underbrace{\mathcal{L}(C;x)}_{\text{likelihood of class } C} \equiv p(x|C) = \int \underbrace{p(x|s)}_{\text{likelihood of } s, \mathcal{L}(s;x)} \underbrace{p(s|C)}_{\text{CCSD (task-dependent)}} ds. \quad (8.23)$$

10. Response distribution

1) 기본 구조

결정은 measurement x 에 의해 이루어진다. 즉 $C \rightarrow s \rightarrow x \rightarrow \hat{C}$

반응 $\hat{C}$ 는 x 의 함수이다. 따라서 response distribution을 구하려면 x 에 대해 주변화를 해야 한다.

2) 핵심 식


$$p(\hat{C}=1|s) = \int_k^\infty \mathcal{N}(x;s,\sigma^2)dx \quad (8.29)$$


$$= \Phi_{\text{standard}}\left(\frac{s-k}{\sigma}\right), \quad (8.30)$$

-> $p(\hat{C} | C)$ 는 “measurement x 가 나올 확률”과 “그 x 에서 해당 반응을 할 확률”을 곱해서 x 에 대해 적분(또는 합)한 것이다.

-> MAP rule은 보통 deterministic하다. 즉, 어떤 x 에서는 반드시 $C=1$ 선택, 어떤 x 에서는 반드시 $C=-1$ 선택. 따라서 이 경우 식이 단순화된다. (8.30 참고)

11. Beyond mirror-image class-conditioned stimulus distributions





(A) CCSD의 차이

그림 (A)은 두 클래스의 자극 분포 $p(s|C=1)$ 과 $p(s|C=2)$ 를 보여준다. 중요한 점은 두 분포가 거의 대칭이 아니라는 것이다. $C=1$ 은 분산이 작아 좁고 뾰족한 분포($\sigma_1=3$)를 가지며, $C=2$ 는 분산이 커서 넓게 퍼진 분포($\sigma_2=12$)를 가진다. 평균은 같지만 분산이 다르다. 즉, 차이는 “위치”가 아니라 “폭(variance)”이다. 이것이 mirror-symmetric 가정이 깨진 상황이다.

(B) 자극 예시

그림 (B)는 두 클래스의 실제 자극 예시이다. 두 클래스 모두 평균적으로 비슷한 orientation을 가지지만, $C=1$ 은 자극의 변동이 작고, $C=2$ 는 변동이 크다. 즉, 클래스 차이가 “평균 방향”이 아니라 “분산 구조”에 있다.

(C) Measurement 분포: noise의 영향

그림 (C)는 measurement x 의 분포 $p(x|C)$ 를 보여준다. 왼쪽은 noise가 없는 경우($\sigma=0$), 오른쪽은 noise가 있는 경우($\sigma=5$)이다.

- noise가 없을 때는 $p(x|C)$ 가 $p(s|C)$ 와 거의 동일한 형태이다. $C=1$ 은 좁고 높고, $C=2$ 는 넓고 낮다.
- noise가 추가되면 두 분포 모두 더 퍼지지만, 여전히 분산 차이는 유지된다. 중요한 점은 평균이 같은데도 분포 모양 차이만으로도 클래스 구분이 가능하다는 것이다.

(D) Log posterior ratio의 형태

그림 (D)는 log posterior ratio d 를 measurement x 의 함수로 그린 것이다.

- noise가 없을 때는 가운데에서 $C=1$ 이 더 그럴듯하고, 양쪽 극단으로 갈수록 $C=2$ 가 더 그럴듯하다. 즉, 가운데 영역은 $C=1$, 양쪽 바깥 영역은 $C=2$ 로 분류된다.
- noise가 있을 때도 구조는 비슷하지만 곡선이 완만해진다.

=> CCSD의 모양(특히 분산 차이)이 decision rule의 형태를 근본적으로 바꿀 수 있다는 것을 시각적으로 보여준다.


Chapter 9. Top-level nuisance variables and ambiguity

1. Plan of the chapter

2가지 classic examples (depth perception & color perception)을 통해 세계 상태 변수에 대한 우도 함수를 계산하기 위한 주변화 방법을 배운다.

2. Example tasks

2가지 세계 상태 변수들이 함께 관측이나 측정을 발생시키는 상황에서, 한 변수는 관심있는 변수, 다른 하나는 최상위 불필요 변수(nuisance variable)로 본다. 이때 최상위 변수의 분포는 문제 내의 다른 변수에 의존하지 않음.



ex 1) 물체까지의 거리 추정 : 물체의 크기가 최상위 불필요 변수 (거리 추정 시 크기에도 의존)

ex 2) 표면의 색 추정 : 입사광의 색이 최상위 불필요 변수

3. Size as a top-level nuisance variable in depth perception


1) 문제 설정: size-depth ambiguity

“크기(size)”가 top-level nuisance variable일 때 어떻게 깊이(depth) 지각에 모호성이 생기는지를 다룬다. 예시는 앞차와의 거리를 추정해야 하는 운전자이다. 시야가 나쁠 때(어두움, 안개 등) 거리 단서가 줄어들면, 운전자는 망막에 맺힌 이미지의 크기 x 를 이용해 거리 D 를 추정해야 한다. 하지만 동일한 망막 크기 x 는 “작은 물체가 가까이 있는 경우”와 “큰 물체가 멀리 있는 경우” 모두에서 발생할 수 있다. 이것이 size-depth ambiguity이다.

2) Step 1: Generative model

모델에는 세 변수 w (실제 물체의 폭), D (거리), x (망막 이미지 폭)가 있다. 기하학적으로 이들은 다

음 관계를 가진다. $x = \frac{lw}{D}$ 즉, 망막 크기 x 는 물체 폭 w 에 비례하고 거리 D 에 반비례한다. 측정 노이즈는 없다고 가정한다.



좌측 이미지는 이 구조를 보여준다. (A)는 기하학적 상황, (B)는 generative

model 구조이다. 중요한 점은 x 가 w 와 D 두 변수에 의해 동시에 결정된다는 것이다. 따라서 w 가 nuisance variable이 된다.

3) Prior 설정

w 와 D 의 결합 prior는 독립이라고 가정한다. $p(D, w) = p(D)p(w)$. 또한 w 와 D 는 음수가 될 수 없으므로, magnitude variable에 적합한 분포가 필요하다. w 에는 lognormal 분포를 가정한다. $p(w) = \text{Lognormal}(w; \mu_w, \sigma_w^2)$. 이는 $\log w$ 가 정규분포를 따른다는 의미이다. D 에 대해서는 단순화를 위해 $\log D$ 에 flat prior를 둔다. $p(\log w) = \mathcal{N}(\log w; \mu_w, \sigma_w^2)$
 $p(\log D) = \text{constant}$. 이후 계산을 쉽게 하기 위해 관계식을 로그 형태로 다시 쓴다.
 $\log x = \log l + \log w - \log D$, 이 식은 $\log x$ 가 $\log w$ 와 $\log D$ 의 선형 결합이라는 것을 보여준다.

4) Step 2: Inference

관찰자는 주어진 x 로부터 D 를 추정한다. Bayes rule을 적용하면 다음과 같다.

$$p(\log D | \log x) \propto p(\log D)p(\log x | \log D) \quad (9.7)$$

$$\propto p(\log x | \log D), \quad (9.8)$$

$\log D$ 에 대한 prior가 flat이므로 posterior는 likelihood에 비례한다. $\log x$ 는 $\log w$ 에 상수를 더한 형태이므로, $\log x | \log D$ 는 정규분포가 된다.

$$p(\log x | \log D) = \mathcal{N}(\log x; \mu_w + \log l - \log D, \sigma_w^2). \quad (9.9)$$

Thus, Eq. (9.8) becomes

$$p(\log D | \log x) \propto \mathcal{N}(\log x; \mu_w + \log l - \log D, \sigma_w^2) \quad (9.10)$$

$$= \mathcal{N}(\log D; \mu_w + \log l - \log x, \sigma_w^2), \quad (9.11)$$

where we made use of the rule $\mathcal{N}(a; b, \sigma^2) = \mathcal{N}(a + c; b + c, \sigma^2)$ for any a, b , and c .

. 따라서 D 자체는 lognormal posterior를 따른다.

$$p(D | x) = \text{LogNormal}(D; \mu_w + \log l - \log x, \sigma_w^2). \quad (9.12)$$

5) Posterior 읽기와 추정값

$\log$ domain에서 제곱오차를 최소화한다고 가정하면, 추정치는 posterior 평균이 된다.

$\log \hat{D} = \mu_w + \log l - \log x$. 이를 원래 변수 D 로 되돌리면 다음과 같다.

$\hat{D} = \frac{l}{x} e^{\mu_w}$. 이 식은 추정된 거리 $\hat{D}$ 가 망막 크기 x 뿐 아니라, prior의 파라미터 μ_w 에 의존함을 보여준다. e^{μ_w} 는 w 의 평균이 아니라 “중앙값(median)”이다. 최종적으로 다음 관계가 나온다.

$$\hat{D} = D \frac{\text{Median}[w]}{w} \quad (9.15)$$

6) nuisance prior가 만드는 bias

이 결과의 중요한 의미는 다음과 같다. 관찰값에는 노이즈가 없지만, w 에 대한 prior 때문에 D 추정이 bias될 수 있다. 실제 차가 평균(정확히는 median)보다 크면, 관찰자는 그것을 “가깝다”고 과소추정한다. 반대로 실제 차가 median보다 작으면 거리를 과대추정한다. 이 bias는 measurement noise 때문이 아니라, nuisance variable(w)에 대해 주변화를 했기 때문에 발생한 다. 즉, nuisance variable의 prior가 관심 변수 D 의 posterior에 직접 영향을 준다.




Figure 9.3: Priors and posteriors over w and D in the car example.




Figure 9.4: Two-dimensional prior, likelihood, and posterior in the car example.

Fig. 9.3과 9.4는 2차원 prior, likelihood, posterior 구조를 시각적으로 보여준다. w 에 대한 prior가 D 의 posterior를 좁혀 ambiguity를 해결한다.




Figure 9.5: Two variants of the Ponzo illusion. In both cases, the topmost figure (line segment) may look taller (wider) even though it is physically equally tall/wide in the drawing.

Fig. 9.5의 Ponzo illusion에서는 망막 크기가 동일한 두 선분이 서로 다른 거리 맥락 속에 놓이면서, 더 멀어 보이는 선분이 더 크게 지각된다. 이는 “같은 망막 크기 + 더 먼 거리”를 동시에 만족하려면 실제 크기가 더 커야 한다는 Bayesian 추론의 결과이다.

4. Marginalization formulation

1) marginalization formulation의 중요성

이 절의 핵심은 “앞에서 구한 $p(\log D | \log x)$ 는 사실 w 에 대해 주변화한 결과”라는 것을 명확히 보여주는 것이다. Bayesian 모델에서는 nuisance variable을 포함한 전체 posterior를 먼저 만든 뒤, 그 변수를 적분해서 제거하는 구조가 기본이다.

2) 2차원 posterior에서 시작

먼저 관심 변수 D 와 nuisance variable w 를 동시에 포함하는 2차원 posterior를 쓴다.

$$p(\log D, \log w | \log x) \propto p(\log D, \log w) p(\log x | \log D, \log w)$$

독립 가정을 쓰면 prior는 $p(D)p(w)$ 형태가 된다.

$$p(\log D, \log w | \log x) \propto p(\log D) p(\log w) p(\log x | \log D, \log w).$$

즉, prior는 2차원 분포이다.

3) Likelihood의 기하학적 의미

이 문제에서 x 는 D 와 w 의 결정론적 함수이므로, (D, w) 평면에서 x 를 만족하는 조합은 한 줄(line) 위에만 존재한다. 따라서 2차원 likelihood는 선 모양이며, 수식으로는 delta function으로 표현된다. $p(\log x | \log D, \log w) = \delta(\log x - (\log l + \log D - \log w))$. 그림 9.4A는 이 선을 보여준다.

4) Prior × Likelihood = slice

2차원 prior 위에 이 선형 likelihood를 곱하면, prior에서 해당 선 위의 부분만 남는다. 즉, posterior는 prior의 한 조각(slice)이다. 그림 9.4C가 이 과정을 시각화한다.

5) 마지막 단계, marginalization

이제 nuisance variable w 를 제거하기 위해 w 에 대해 적분한다.

$p(\log D | \log x) = \int p(\log D, \log w | \log x) d(\log w)$ 이 적분이 2차원 posterior를 1차원 posterior $p(\log D | \log x)$ 로 collapse 하는 과정이다. marginalization이란 말 그대로 한 차원을 접어서 margin으로 보내는 것.

5. In color perception

1) 기본 아이디어

색 지각 문제는 깊이 지각과 구조가 거의 동일하다. 관심 변수는 표면의 shade(= reflectance, ρ)이고, nuisance variable은 조명의 세기 I 이다. 망막에 도달하는 빛의 양 x 는 이 둘의 곱으로 결정된다.

2) Generative model

세계 상태는 표면의 reflectance ρ 와 조명 세기 I 이다. 측정값은 망막 강도 x 이며, 노이즈가 없다고 가정하면 $x = \rho I$ 이다. 로그로 쓰면 $\log x = \log \rho + \log I$.
이 식은 자동차 예시의 $\log x = \log l + \log w - \log D$ 와 동일한 구조를 가진다.

3) 모호성의 본질

하나의 retinal intensity x 는 무한히 많은 (ρ, I) 조합과 일치한다. 예를 들어, 어두운 종이가 강한 빛을 받는 경우와 밝은 종이가 약한 빛을 받는 경우는 같은 x 를 만들 수 있다. 따라서 retinal intensity 자체만으로는 표면의 shade를 결정할 수 없다. 우리가 지각하는 lightness는 단순한 물리량이 아니라 추론의 결과이다.

4) nuisance variable의 역할

색 지각에서 조명 세기 I 는 nuisance variable이다. shade를 추정하려면 I 에 대해 주변화하거나, 다른 단서를 통해 I 를 추정해야 한다. 이 과정이 “discounting the illuminant”이다. 즉, 먼저 조명을 추정하고, 그 영향을 제거한 뒤 표면의 reflectance를 추론한다.

5) 맥락 단서와 착시

조명에 대한 불확실성을 줄이면 모호성이 해소된다.




그림 A~C 처럼 다른 관찰 정보가 조명 상태를 알려주면, 그 정보를 이용해 shade posterior를 계산할 수 있다. Simultaneous contrast illusion에서는 두 중앙 사각형의 retinal intensity가 같아도, 주변 맥락이 조명이 다르다고 암시하면 서로 다른 밝기로 지각된다. 이는 뇌가 조명을 추론한 뒤 shade를 추정하기 때문이다.

6) “The Dress” 현상

같은 retinal 입력을 보고도 어떤 사람은 파랑/검정, 어떤 사람은 흰색/금색으로 본다. 이는 각 개

인이 조명(power spectrum)에 대해 서로 다른 prior를 가지고 있기 때문이다. 즉, nuisance variable(조명)에 대한 가정 차이가 최종 지각 차이를 만든다.


=> 색 지각의 계산 구조는 depth 예시와 동일하다. 관찰값 x 는 관심 변수(p)와 nuisance variable(l)의 결합 결과이며, 이를 분리하기 위해 prior와 맥락 정보를 사용한다. 지각은 generative model 위에서 nuisance variable을 처리한 Bayesian 추론의 결과이다.

6. In object recognition

1) 문제의 핵심 구조

객체 인식에서 우리가 관심 있는 것은 객체의 정체(identity) C 이다. 하지만 망막에 들어오는 이미지는 객체 정체뿐 아니라 촬영 각도(viewing angle) θ 에도 의해 결정된다. 우리는 각도에는 관심이 없지만, 각도는 이미지 s 를 결정하는 데 필수적이다. 따라서 θ 는 top-level nuisance variable이다. 뇌는 각도를 “discount”하고 객체 정체만을 추론해야 한다. 이것이 **viewpoint-invariant recognition**의 의미이다.

2) Generative model



모델에는 세 변수 C (객체 클래스), θ (촬영 각도), s (이미지)가 있다. 구조는 C 와 θ 가 함께 s 를 생성하는 형태이다. C 와 θ 는 독립이라고 가정한다. 즉, 특정 객체가 특정 각도로 더 자주 찍힌다는 가정은 X. 분포는 $p(C)$, $p(\theta)$, 그리고 $p(s|C, \theta)$ 이다. 우리가 최종적으로 구하고 싶은 것은 $p(C|s)$.

3) Bayes rule 적용

객체 posterior는 Bayes rule로 시작한다.

$$p(C|s) \propto p(s|C)p(C) \quad (9.21)$$

즉, $p(C|s)$ 는 likelihood $p(s|C)$ 와 prior $p(C)$ 에 비례한다.

4) 각도에 대한 주변화

$p(s|C)$ 는 바로 주어지지 않는다. 이미지는 각도 θ 에 따라 달라지므로, class likelihood는 θ 에 대해 주변화해야 한다.

$$p(s|C) = \int p(s|C, \theta)p(\theta|C)d\theta \quad (9.22)$$

C 와 θ 가 독립이므로 $p(\theta|C)=p(\theta)$ 이고, 식은 다음처럼 단순화된다.

$$= \int p(s|C, \theta) p(\theta) d\theta \quad (9.23)$$

-> 모든 가능한 시점에서의 생성 가능성을 평균내는 것

=> 객체 인식에서도 본질은 동일하다. 관심 변수 C 를 추정하기 위해 nuisance variable θ 에 대해 적분한다. 즉, 뇌는 “이 객체가 여러 각도에서 어떻게 보일 수 있는가”를 내부적으로 고려한 뒤, 그 가능성들을 평균내어 class likelihood를 만든다. 이 과정을 통해 posterior $p(C|s)$ 를 계산하고, 가장 높은 posterior를 갖는 객체를 선택한다.