

Chap10

이 장의 질문은 “두 자극이 같은가 다른가”이다. 단순히 보이지만, 분류 문제와 성질이 다르다. 분류는 하나의 자극이 어떤 범주에 속하는지(예: 이게 A냐 B냐)를 추론한다. 여기서는 두 자극의 관계를 추론한다. 즉, 실제 세계에서 중요한 것은 두 관측이 같은 원인에서 생긴 것인지(공통 원인) 아니면 서로 다른 원인에서 생긴 것인지(별개 원인)라는 구조적 질문이다. 책에서는 이 관계 판단을 same-different judgment라고 부르고, 이 문제가 이후 장의 causal inference(원인 구조 추론), 다감각 통합, 지각적 조직화(게슈탈트)까지 연결된다고 알아둔다.

1. 핵심 아이디어: “자극 값”이 아니라 “원인의 개수”를 추론한다.

이 장의 변수 표기는 보통 다음처럼 잡힌다.

관측(측정값)

x_1, x_2

각 자극을 직접 보는 것이 아니라 감각 노이즈가 섞인 측정값을 얻는다고 본다.

잠재 자극

s_1, s_2

실제 세계의 자극 값이다.

관심 세계변수(구조 변수)

C

$C=1$ 이면 same, 즉 공통 원인이라서 s_1 과 s_2 가 같은 자극에서 나온다.

$C=2$ 이면 different, 즉 두 원인이라서 s_1 과 s_2 가 별개로 생성된다.

따라서 이 장의 중심 목표는 $p(C | x_1, x_2)$ 같은 “원인 구조의 사후확률”을 계산하고, 그에 따라 응답을 결정하는 것이다.

2. 10.2 Binary stimuli: 자극이 두 값만 가지는 경우

2.1 Step 1 Generative model(생성모형)

먼저 자극이 이산적으로 두 값만 가진다고 한다. 예를 들어 s 는 $+\mu$ 또는 $-\mu$ 만 가능. 이 때 핵심은 C 에 따라 s_1, s_2 의 결합분포가 달라진다는 점이다.

$C=1$ (same)일 때

$s_1=s_2$ 가 되어야 한다. 가능한 조합은 $(+\mu, +\mu)$ 또는 $(-\mu, -\mu)$ 두 가지뿐이고 각각 확률 0.5로 둔다.

C=2(different)일 때

s_1 과 s_2 는 독립적으로 $+\mu$ 또는 $-\mu$ 를 가진다. 가능한 조합이 네 가지이며, 그중 "다른 부호"인 조합이 포함된다.

그리고 관측은 감각노이즈가 섞인 가우시안으로 둔다.

$$p(x_1 | s_1) = N(x_1; s_1, \sigma^2)$$

$$p(x_2 | s_2) = N(x_2; s_2, \sigma^2)$$

또한 책에서는 (x_1, x_2) 가 조건부 독립이라고 둔다. 즉 s_1, s_2 가 주어지면 x_1 과 x_2 의 노이즈는 서로 독립이다.

2.2 Step 2 Inference(추론): 사후비로 정리하기

관심은 $p(C | x_1, x_2)$ 이다. 베이즈 규칙을 쓰면

$$p(C | x_1, x_2) \propto p(x_1, x_2 | C) p(C)$$

결정 규칙을 만들 때는 두 가설 $C=1$ 과 $C=2$ 를 비교하면 되므로, 책은 "로그 사후비"를 정의한다.

$$d = \log [p(C=1 | x_1, x_2) / p(C=2 | x_1, x_2)]$$

베이즈 규칙을 대입하면, 로그 사후비는 항상 "로그 가능도비 + 로그 사전비"로 분해된다.

$$d = \log [p(x_1, x_2 | C=1) / p(x_1, x_2 | C=2)] + \log [p(C=1) / p(C=2)]$$

이 형태가 굉장히 중요하다. 왜냐하면 뒤에서 여러 문제들이 "가능도비"를 어떻게 계산하느냐로 귀결되기 때문이다.

여기서 관건은 $p(x_1, x_2 | C)$ 를 계산하려면 s_1, s_2 가 숨어있으므로 주변화(marginalization)가 필요하다는 점이다.

$$p(x_1, x_2 | C) = \sum_{s_1} \sum_{s_2} p(x_1 | s_1) p(x_2 | s_2) p(s_1, s_2 | C)$$

Binary이므로 합이 간단히 끝난다(가능한 조합이 4개뿐). 책은 이 주변화를 거쳐서 d 를 x_1, x_2 의 함수로 정리하고, 최종적으로 관측값이 비슷할수록 same에 유리해진다는 해석을 만든다.

2.3 MAP decision rule(결정 규칙)

MAP(maximum a posteriori) 관찰자는 사후확률이 더 큰 쪽을 선택한다. 이는 로그 사후 비로 쓰면 아주 단순해진다.

$d > 0$ 이면 same($C=1$) 응답

$d < 0$ 이면 different($C=2$) 응답

즉, 경계는 $d=0$ 인 곡선이다.

2.4 Step 3 Response probabilities(반응확률): 사람이 항상 같은 답을 하지 않는 이유

같은 (s_1, s_2) 조건에서도 x_1, x_2 가 노이즈 때문에 바뀌므로, 응답은 확률적이다. 그래서 "특정 자극 조건에서 same을 말할 확률"은

$$p(\hat{C}=1 \mid s_1, s_2) = \iint_{\{d(x_1, x_2) > 0\}} p(x_1 \mid s_1) p(x_2 \mid s_2) dx_1 dx_2$$

이 적분은 영역($d > 0$) 위에서의 확률 질량이므로, "결정경계가 측정 분포를 얼마나 가르나"로 해석할 수 있다. 이게 바로 psychometric function이 된다.

다만 결정영역이 복잡하면 해석적 적분이 어렵다. 그래서 책은 다차원 적분을 계산하는 대표적 방법을 설명한다.

첫째, 수치적 적분(grid 기반)

(x_1, x_2) 평면을 촘촘한 격자로 나누고 각 점에서 $d > 0$ 여부를 체크해서 영역을 근사한다.

둘째, 몬테카를로 시뮬레이션

(s_1, s_2) 에서 x_1, x_2 샘플을 많이 뽑아서, $d > 0$ 이 되는 비율을 확률로 근사한다.

책의 강조점은 "다차원 적분은 차원이 조금만 올라가도 매우 비싸진다"는 현실이다. 이 메시지는 11장 search에서 더 크게 다시 나온다.

3. 10.3 Continuous stimuli: 자극이 연속값일 때는 무엇이 달라지나

10.2는 자극이 두 값만 가져서 합으로 끝났다. 현실 자극은 연속이므로 이제는 적분이 등장한다. 그런데 문제의 본질은 여전히 "공통 원인($C=1$)인가, 별개 원인($C=2$)인가"이다.

3.1 Step 1 Generative model(생성모형)

$C=1$ (same)일 때는 사실 자극이 하나만 있다. 즉 s 하나가 있고, 두 측정이 그로부터 나온다.

$$x_1 \sim N(s, \sigma_1^2)$$

$$x_2 \sim N(s, \sigma_2^2)$$

C=2(different)일 때는 s_1, s_2 가 각각 존재하고

$$x_1 \sim N(s_1, \sigma_1^2)$$

$$x_2 \sim N(s_2, \sigma_2^2)$$

여기서 σ_1 과 σ_2 를 다르게 둘 수 있게 해서, 두 감각 채널 혹은 두 측정이 서로 다른 신뢰도를 갖는 상황을 모델링한다.

3.2 Step 2 Inference(추론): 주변화가 연속 적분으로 바뀐다

Binary에서는 Σ 였는데, 연속에서는 $\int$ 가 된다.

$$p(x_1, x_2 | C=1) = \int p(x_1|s)p(x_2|s)p(s|C=1) ds$$

$$p(x_1, x_2 | C=2) = \iint p(x_1|s_1)p(x_2|s_2)p(s_1, s_2|C=2) ds_1 ds_2$$

그리고 다시

$$d = \log [p(x_1, x_2|C=1) / p(x_1, x_2|C=2)] + \log [p(C=1)/p(C=2)]$$

책은 이 결과를 "결국 x_1 과 x_2 가 가까우면 same"이라는 방향으로 해석하고, 그림으로 d 의 등고선을 보여준다.

첫째, $d=0$ 경계가 $x_1=x_2$ 직선과 비슷한 형태로 나온다.

둘째, 측정 노이즈가 작을수록(정확할수록) 경계가 날카로워진다.

셋째, 사전확률 $p(C=1)$ 가 크면 same 쪽으로 더 쉽게 기울어진다.

3.3 Step 3 Response probabilities

연속 자극에서도 동일하게, 특정 조건에서 same을 말할 확률은 $d>0$ 영역의 적분이다.

다만 이번엔 (x_1, x_2) 분포가 연속이고, 모수들이 많아질수록 수치기법 의존이 커진다.

4. 10.3.4 Step 2 revisited: C를 모른다는 것이 자극 추정에도 영향을 준다

책이 중요한 포인트로 다시 돌아오는 부분이다. 우리는 C만 추론하는 것이 아니라, 자극 자체의 사후분포도 관심이 될 수 있다.

$$p(s_1, s_2 | x_1, x_2)$$

그런데 실제로는 C가 불확실하므로, 최종 사후는 C에 대한 가중합으로 표현된다.

$$p(s_1, s_2 | x_1, x_2) = p(C=1|x_1, x_2) p(s_1, s_2|x_1, x_2, C=1) + p(C=2|x_1, x_2) p(s_1, s_2|x_1, x_2, C=2)$$

이게 "모형 평균(model averaging)"이다. 애매하면 한 가설로 확정하지 않고 가설들을 섞어서 추론하는 결과가 나온다.

5. 10.4 Multiple-item sameness judgment: N개 자극이 모두 같은가

이제 자극이 두 개가 아니라 N 개다. 질문은 "모두 같은 하나의 원인에서 나온 건가"이다. 여기서 C 는 여전히 이진이다.

$C=1$ 이면 모든 자극이 동일한 s 에서 생성

$C=0$ 이면 각 자극이 서로 독립

관측은 $x_1 \dots x_N$. 핵심은 $p(x|C=1)$ 과 $p(x|C=0)$ 를 비교하는데, $C=1$ 에서는 공통 s 를 적분해야 해서 고차원 적분 문제가 생긴다.

그런데 책은 조건부 독립성과 곱 구조를 이용해서 계산을 단순화할 수 있음을 보여준다. N 개로 확장해도 프레임은 그대로, 계산만 어려워진다.

6. 10.5 Perceptual organization: 게슈탈트 원리를 베이지안으로 보기

이 절은 "같다/다르다" 문제가 사실 지각적 조직화에도 똑같이 적용된다는 것을 보여준다. 게슈탈트 법칙은 흔히 규칙처럼 외우지만, 여기서는 생성모형 관점에서 "어떤 구조 가설이 더 그럴듯한가"로 바꿔 읽는다.

6.1 Kanizsa triangle 같은 착시

불완전한 단서만 있어도 뇌가 어떤 구조(흰 삼각형이 위에 있다)를 지각하는 이유는, 그 구조 가설이 생성모형 관점에서 사후확률이 더 크기 때문이라고 해석한다.

6.2 Contour integration(윤곽선 통합)

점이나 짧은 선분들이 "한 개의 윤곽선인가, 두 개의 윤곽선인가"를 판단하는 문제로 형식화한다.

여기서도 world state(원인 구조)가 C 처럼 들어가고, 관측된 edge element들이 그 구조 하에서 얼마나 그럴듯한지 가능도를 계산한다.

첫째, 게슈탈트 법칙은 "가설 공간"을 정의하는 역할을 한다.

둘째, 실제 선택은 "가능도 $\times$ 사전확률"의 비교로 나온다.

Chap11

Search는 “많은 자극 중에서 목표를 찾는” 문제다. 책은 search를 다룰 때도 본질을 “추론 문제”로 둔다. 즉, 목표의 위치나 존재 여부 같은 숨은 변수를 추론하고, 그에 따라 행동(응답)을 결정한다.

책이 구분하는 대표 유형은 세 가지다.

첫째, target localization(목표 위치 찾기)

둘째, target detection(목표가 있나 없나)

셋째, target categorization(목표가 무엇인가)

이 장에서는 주로 첫째와 둘째를 다룬다.

1. 11.2 Target localization: camouflage(노이즈 없는 기본 위치추정)

책은 위장(camouflage) 예시로 시작한다. 물고기(타겟)가 자갈(방해자) 사이에 숨어 있고, 관찰자는 어느 위치에 물고기가 있는지 맞춘다.

1.1 생성모형

위치 변수

$$L \in \{1, \dots, N\}$$

각 위치의 자극 값

$$s_1, \dots, s_N$$

L 이 주어지면

s_L 은 타겟 분포 $p_{\text{target}}(s)$ 에서 생성

나머지는 방해자 분포 $p_{\text{distractor}}(s)$ 에서 생성

즉

$$p(s | L) = p_{\text{target}}(s_L) \prod_{i \neq L} p_{\text{distractor}}(s_i)$$

그리고 책의 첫 버전에서는 measurement noise를 없애서, 관측이 곧 자극이라고 둔다.

즉 x 가 아니라 s 를 바로 본다. 이게 11.2의 단순화다.

1.2 추론

관심은 $p(L | s)$ 이다.

$$p(L | s) \propto p(s | L) p(L)$$

사전 $p(L)$ 은 균일로 둔다(어느 위치든 같을 확률). 그러면 비교는 사실상 $p(s|L)$ 만 보면 된

다.

그런데 $p(s|L)$ 을 위의 곱 형태로 보면, 위치 L 에 대한 비교가 매우 단순해진다. 각 후보 L 에 대해

$$\text{score}(L) \propto p_{\text{target}}(s_L) \prod_{i \neq L} p_{\text{distractor}}(s_i)$$

하지만 $\prod_{i \neq L} p_{\text{distractor}}(s_i)$ 는 L 에 따라 거의 공통 부분이어서, 결국 결정은 "그 위치가 타겟일 때의 가능성도"가 크냐에 의해 좌우된다. 책은 이를 likelihood ratio 형태로 정리한다.

local likelihood ratio

$$\text{LR}_i = p_{\text{target}}(s_i) / p_{\text{distractor}}(s_i)$$

그러면 MAP 위치추정은 "LR이 가장 큰 위치를 고른다"가 된다.

$$L_{\text{hat}} = \text{argmax}_i \text{LR}_i$$

Search의 위치추정은 각 위치를 "타겟 vs 방해자 분류"로 보고, 그 증거를 비교하는 방식으로 떨어진다.

2. 11.3 Target localization with measurement noise(측정 노이즈가 있는 위치추정)

이제 현실적으로 관측은 $x_1, \dots, x_N$ 이고, 자극 $s_1, \dots, s_N$ 은 잠재변수다. 그러면 likelihood 계산에 주변화가 들어간다.

2.1 생성모형

L 은 여전히 타겟 위치.

각 위치에서

$$s_i \sim p_{\text{target}}(s) \text{ 또는 } p_{\text{distractor}}(s)$$

그리고

$$x_i \sim p(x_i | s_i)$$

책의 예시는 가우시안으로 두 분포가 겹칠 수 있음을 보여준다. 즉 타겟과 방해자가 자극공간에서 완전히 분리되지 않아 혼동이 생긴다.

2.2 추론과 주변화

$$p(L | x) \propto p(x | L)p(L)$$

여기서

$$p(x | L) = \int \dots \int p(x | s) p(s | L) ds$$

겉보기에는 N차원 적분이라 끔찍해 보이지만, 조건부 독립성과 곱 구조를 이용하면 분해가 된다. 책은 "다차원 적분이 1차원 적분의 곱으로 factorize된다"는 박스(다중적분 분해)를 통해 계산 가능성을 강조한다.

결과적으로, 각 위치 i 에 대해 "주변화된 local evidence"를 계산할 수 있다.

$$m_i = \int p(x_i | s) p_{\text{target}}(s) ds$$

$$n_i = \int p(x_i | s) p_{\text{distractor}}(s) ds$$

그 다음 local LR은

$$LR_i = m_i / n_i$$

그리고 결정은 여전히

$$L_{\text{hat}} = \operatorname{argmax}_i LR_i$$

노이즈가 추가되면 local LR이 단순한 $p_{\text{target}}(s_i)/p_{\text{distractor}}(s_i)$ 가 아니라, s 에 대해 적분한 형태로 바뀐다

3. 11.4 Target detection: camouflage(목표 존재 여부 판단)

이제 질문이 바뀐다. "어딘지"가 아니라 "있는지 없는지"다.

3.1 세계변수

$C=1$ 타겟 존재

$C=0$ 타겟 부재

만약 $C=0$ 이면 모든 위치가 distractor 분포.

만약 $C=1$ 이면 어떤 한 위치 L 이 타겟이고 나머지는 distractor.

즉 $C=1$ 은 L 이라는 추가 변수를 포함한다. 그래서 detection에서는 L 이 nuisance parameter(귀찮은 변수)로 등장하고, 이것을 주변화해야 한다.

3.2 로그 사후비와 likelihood ratio

결정은 again 두 가설 비교다.

$$\begin{aligned} d &= \log [p(C=1 | x) / p(C=0 | x)] \\ &= \log [p(x|C=1) / p(x|C=0)] + \log [p(C=1) / p(C=0)] \end{aligned}$$

핵심은 $p(x|C=1)$ 에서 L 을 합(또는 적분)으로 없애야 한다는 점.

$$p(x|C=1) = \sum_L p(L) p(x|L, C=1)$$

이때 앞에서 정의한 local LR들이 자연스럽게 들어오며, 책은 "global LR이 local LR들의 평균 형태"로 정리되는 결과를 준다.

즉, detection은 단순히 "가장 수상한 위치 하나"만 보는 게 아니라, 여러 위치의 증거가 통합되어야 한다.

local LR이 큰 위치가 하나라도 있으면 타겟 존재 쪽으로 흔들린다.

하지만 local LR이 약하게 여러 개 모여도 global evidence가 커질 수 있다.

따라서 detection은 evidence integration(증거 통합) 문제다.

4. 11.5 Target detection with measurement noise(노이즈 있는 탐지)

이제 detection에서도 s 가 잠재변수면, 각 위치 evidence가 주변화된 형태가 된다. 구조는 11.3과 똑같다.

핵심은 "local LR을 먼저 계산할 수 있고, global decision variable이 local LR들을 어떤 방식으로 모으는가"다. 책은 여전히 global log LR이 local LR들로 표현된다는 연결을 보여 주면서, search 문제에서 반복되는 공통 패턴을 강조한다.

5. 11.6 Applications: 실제 인간 탐색과 연결되는 해석 포인트

책은 많은 실험 문헌에서 인간이 완전히 최적(MAP)과 같지는 않지만, 비슷한 구조를 보인다고 말한다. 그리고 중요한 관찰은 다음과 같다.

첫째, distractor들이 서로 이질적(heterogeneous)일수록 감각 노이즈가 사실상 커진 것처럼 행동이 어려워진다.

둘째, set size(N)가 늘어나면 오류가 늘어나는 경향이 있다. 이건 evidence 통합 과정의 통계적 부담과도 연결된다.

셋째, 탐색에서 시선 이동이나 능동적 탐색(active search) 같은 요소는 이 장의 단순 모델 밖이지만, 기본 inference 틀은 유지된다.

이 장의 요지는 search를 베이저안 추론으로 보면, 위치추정은 L 추론이고 탐지는 C 추론이며, 조건부 독립성 덕분에 고차원 문제가 local evidence 계산으로 쪼개지고, 최종 결정은 그 local evidence의 비교 또는 통합으로 나타난다.

최종요점!

1. Chapter 10의 핵심은 두 자극이 같은지 다른지를 판단하는 문제가 사실은 “공통 원인인가 아닌가”라는 구조 추론 문제라는 점이다.
2. 관측값은 노이즈가 섞여 있으므로, 우리는 자극 자체가 아니라 원인 변수 C 에 대한 사후확률 $p(C \mid x_1, x_2)$ 를 계산해야 한다.
3. 결정은 항상 로그 사후비, 즉 로그 가능도비에 사전확률을 더한 값이 0보다 큰지 작은지로 정리된다.
4. Continuous 모델에서는 잠재 자극을 적분으로 주변화해야 하며, 이것이 베이지안 구조 추론의 핵심 계산 단계다.
5. Multiple-item이나 지각적 조직화 문제도 동일하게 “어떤 구조 가설이 더 그럴듯한가”를 비교하는 문제로 환원된다.
6. Chapter 11에서는 탐색을 위치 변수 L 또는 존재 변수 C 를 추론하는 베이지안 문제로 형식화한다.
7. 조건부 독립성 덕분에 복잡해 보이는 다차원 문제도 각 위치의 local likelihood ratio 계산으로 분해된다.
8. 결국 두 장 모두 생성모형을 세우고, 잠재변수를 주변화한 뒤, 사후확률 또는 가능도비를 비교해 MAP 결정을 내리는 동일한 추론 구조를 공유한다.