

12장. 변화하는 세상에서의 추론 (Inference in a Changing World)


1. 세계의 상태가 법칙에 따라 지속적으로 변하는 경우

ex) 스포츠 게임에서 상대 선수의 움직임 추적, 어두운 방에서 스위치를 찾을 때 내 손의 움직임, 음성 정보나 청각 정보의 수집, 동물이 먹이를 찾을 때 등

-> 생성 모델: 은닉 마르코프 모델(HMM: Hidden Markov Model)

step1) 생성 모델 (Generative Model)

수학을 단순하게 만들기 위해 시간을 이산화. (시간은 초 단위와 같은 일정한 단계로 흐른다고 가정) t =정수이며, $t=1$ 에서 시작



구조: s_t 는 시간 t 에서의 세계 상태를, x_t 는 그 시점의 측정값을 나타냄.

마르코프 속성(Markov Property): 현재 상태 s_t 의 분포가 오직 바로 직전 상태인 s_{t-1} 에만 의존하고 그 이전의 상태에는 의존하지 않는다는 가정. 이를 1차 마르코프 과정이라고 함.

상태 전이 모델: 가장 간단한 모델. 상태가 시간 단계마다 고정된 값 Δ 만큼 증가한다고 가정하면 $s_t = s_{t-1} + \Delta$ 여기에 가우시안 소음인 σ 를 더해준다.

*이 장에서는 '자극(stimulus)' 대신 '세계 상태(world state)'라는 용어를 사용.


자극=물리적으로 제시된 세계 상태가 이후 내부 소음에 의해 오염됨을 시사

Step2) 추론(Inference)

관찰자는 현재 상태 s_t 를 과거의 측정값 $x_1, x_2, \dots, x_t$ 를 바탕으로 추론하려고 함.

여기서 마르코프 성질(Markov property) 덕분에 계산이 단순해짐.

즉, 현재 상태에 대한 사후분포(posterior)는 이전 상태에 대한 사후분포를 이용해 재귀적으로 표현할 수 있음.



(A) 단일 상태와 관측

- 세계의 상태가 오직 현재 상태 s_t 하나뿐이고, 이에 대응하는 측정값 x_t 만 있다고 가정.
- 상태 s_t 는 분포 $p(s_t)$ 를 따르며, 이는 관찰자가 사용하는 사전분포(prior)이다.
- 이 경우 사후분포는 단순히 베이즈 정리를 적용하면 된다.

$$p(s_t | x_t) \propto p(x_t | s_t) p(s_t)$$

(B) 이전 상태 추가

- 이제 이전 상태 s_{t-1} 를 모델에 추가하면 s_{t-1} 는 분포 $p(s_{t-1})$ 를 따름.
- 그러면 현재 상태 s_t 의 사전분포는 직접 알 수 없고, 이전 상태를 적분해서 얻어야 함.

$$p(s_t) = \int p(s_t | s_{t-1}) p(s_{t-1}) ds_{t-1}$$

- 의미: 관찰자가 현재 상태에 대한 믿음을 이전 상태에서부터 "예측(prediction)"하거나 "외삽(extrapolation)"하는 과정임을 보여준다.


(C) 전체 시계열 고려

- 실제로는 관찰자가 단순한 사전분포가 아니라, 과거 모든 데이터 $x_1, \dots, x_{t-1}$ 에 기반한 사후분포를 가지고 있다.

- 따라서 재귀식은 다음과 같이 됨

$$p(s_t | x_1, \dots, x_t) \propto p(x_t | s_t) \int p(s_t | s_{t-1}) p(s_{t-1} | x_1, \dots, x_{t-1}) ds_{t-1}$$

즉, 현재 시점의 사후분포는 이전 시점의 사후분포와 상태 전이 모델을 이용해 예측한 뒤, 새로운 관측값으로 업데이트하는 방식.



t = 1 (첫 번째 시점)

- 노란색: 초기 사전분포 (prior) → 평균 μ_0 , 분산 σ_0^2 .
- 빨간색: 관측값 x_1 에 대한 가능도 (likelihood).
- 파란색: posterior → prior와 likelihood를 결합한 결과.

t = 2 (두 번째 시점)

- 이전 시점의 posterior가 새로운 prior로 넘어옴
- 이때 prior는 평균이 Δ 만큼 이동하고, 분산이 σ_s^2 만큼 넓어짐.
- 새로운 관측값 x_2 의 likelihood와 결합해 posterior를 다시 계산.

t = 3 (세 번째 시점)

- 같은 과정 반복: posterior → prior로 이동하면서 Δ 만큼 shift, noise 때문에 더 넓어짐.
- likelihood와 결합해 posterior를 얻음.


예측 단계: 이전 상태에서 현재 상태를 추정 → 평균 이동, 분산 증가.

갱신 단계: 새로운 관측값을 반영 → 평균이 관측값 쪽으로 당겨지고, 분산이 줄어듦.

이 과정을 반복하면 시스템은 점점 더 안정적으로 상태를 추적할 수 있음.

이는 곧 칼만 필터(Kalman filter)의 기본 원리와 동일.

2. 변화가 불연속적인 시점에 발생하는 경우 (12.2)



Step 1: 생성 모델

- 가정: $t = 1$ 부터 $t = T$ 까지 모든 시점이 동일한 확률로 변화점(change point)이 될 수 있음.

$$p(t_{\text{change}}) = \frac{1}{T}$$

- 변화점이 t_{change} 에서 발생한다는 의미는 다음과 같음:

$$s_t = s_{\text{pre}} \text{ for } t < t_{\text{change}}$$

$$s_t = s_{\text{post}} \text{ for } t \geq t_{\text{change}}$$

여기서 s_{pre} 와 s_{post} 는 변화점 전후의 상태이며, 관찰자가 알고 있다고 가정.

- 측정값들은 조건부 독립이고, 정규분포를 따른다고 가정:

$$p(x | s) = \prod_{t=1}^T p(x_t | s_t) = \prod_{t=1}^T \mathcal{N}(x_t; s_t, \sigma^2)$$

즉, 각 시점의 관측값은 해당 상태를 평균으로 하는 정규분포에서 발생.

Step 2: 추론 (Inference)

- 관심 있는 세계 상태는 변화점 시각 t_{change} 이다.
- 따라서 베이지 관찰자는 측정값 시퀀스 x 가 주어졌을 때 변화점 시각에 대한 사후분포를 계산한다.
- 균일한 사전분포를 가정하면:

$$p(t_{\text{change}} | x) \propto p(x | t_{\text{change}}) p(t_{\text{change}}) \propto p(x | t_{\text{change}})$$


- 다음으로 상태 s 에 대해 주변화(marginalization)를 수행한다:

$$p(t_{\text{change}} | x) \propto \sum_s p(x | s) p(s | t_{\text{change}})$$

핵심 요약

- 변화점 전후로 상태가 달라지고, 관측값은 해당 상태를 평균으로 하는 정규분포에서 발생한다.
- 추론의 목표는 변화점 시각 t_{change} 을 찾는 것.
- 베이지 정리를 적용하면, 사후분포는 관측값 시퀀스에 기반해 계산되며, 이는 상태에 대한 주변화를 통해 얻어진다.

변화점이 무작위로 발생하는 경우의 생성모델



무작위 변화점 모델에서는 각 시점마다 변화가 발생할 확률 ε 을 가정.

변화점 벡터 c 는 가능한 모든 조합(총 2^T)을 고려해야 하며 사후분포는 관측값 x 와 변화점 벡터 c 의 결합 확률로 계산.

사전분포 $p(C)$ 는 변화점 개수에 따라 달라지며, 변화점이 많을수록 $\varepsilon^{\|C\|}$ 항이 커짐.

한편 현실세계의 실제 변화점은 단일/무작위 가정보다 더 복잡하게 발생.

변화점 간 간격에 대한 사전분포가 필요하며 온라인 탐지(실시간 판단)가 중요 (->15장)

13장 추론과 유용성의 결합(Combining inference with utility)

기존 모델의 한계: 지금까지 우리는 지각적 의사결정을 관찰자가 세계 상태에 대한 사후 확률을 계산한 뒤 진실에 가장 가까운 추정치를 내놓는 과정으로 모델링해 왔음.

그러나 실제 생활에서 우리는 단순히 세계 상태를 추정하는 데 그치지 않고 보상이나 비용으로 이어지는 결과를 초래하는 행동을 수행.

베이지안 결정 이론: 최적의 행동은 단순히 확률이 높은 것을 고르는 게 아니라, 기대 유용성(Expected Utility)을 최대화하는 것.

Ex) 비 올 확률이 30%밖에 안 되더라도, 비에 젖었을 때의 손해(비용)가 우산을 들고 다니는 번거로움보다 훨씬 크다면 우산을 챙기는 것이 베이지안 관점에서는 최적임.

지각과 행동의 연결: 우리가 무언가를 보고 판단하는 '순수 지각' 조차도 실제로는 오차를 최소화하려는 뇌의 숨겨진 비용 함수가 작동한 결과.

실제 응용: 시각적 판단 실험, 물체에 손을 뻗는 운동 제어, 자신의 판단에 대한 확신(신뢰 구간) 설정 등 실생활에서 인간이 얼마나 효율적으로 확률과 가치를 결합하는지 보여줌.

주관성: 중요한점은 결과에 부여하는 비용이나 유용성은 개인적 선호를 반영하며 본질적으로 주관적이라는 것. 따라서 동일한 사후 확률을 가졌더라도 결과에 부여하는 수치적 비용이 다르면 서로 반대의 선택을 할 수 있음.

		World State (location of keys)			Costs: — find keys: -80 — easy to do: 1 — inconvenience friend: 5 — disappointing result: 10 — big inconvenience: 80
		Your friend's car prob. = 0.1	Another pocket prob. = 0.1	The park prob. = 0.8	
Action	Search car	inconvenience friend, find keys! cost = -75	inconvenience friend, disappointing result cost = 15	inconvenience friend, disappointing friend cost = 15	
	Search pockets	easy to do, disappointing result cost = 11	easy to do, find keys! cost = -79	easy to do, disappointing result cost = 11	
	Search park	big inconvenience, disappointing result cost = 90	big inconvenience, disappointing result cost = 90	big inconvenience, find keys! cost = 0	

열쇠찾기 문제. 그림을 보면 열쇠가 공원에 있을 확률이 가장 높아도 주머니 뒤지는게 쉬우므로 주머니를 먼저 뒤집.

베이지안 수색: 잃어버린 귀중품을 찾는 데 성공적으로 사용되었으며, 특히 바다에서 실종된 선박을 찾는 데 흔히 쓰임. 핵잠수함 USS 스콜피온호나 에어프랑스 447편 수색이 유명한 예. 수색 격자판의 각 칸에 사전 확률을 할당하고, 수색 비용(수심, 지형 등)을 고려하여 최적 수색 위치를 계속 업데이트.

유용성 함수 $U(s, a)$: 상태 s 와 행동 a 의 함수로 정의됨. 보상은 양의 유용성, 비용은 음의 유용성

의사결정의 핵심: 기대 유용성 최대화

- 기대 유용성(EU): 어떤 행동 a 를 했을 때 얻을 수 있는 가치(유용성, U)에 그 상황 (s)이 발생할 확률(사후 확률, $p(s|x)$)을 곱하여 합산한 값.
- 최적의 선택: 베이지안 결정 이론에 따르면, 에이전트는 가능한 모든 행동 중 기대 유용성이 가장 높은 행동을 선택.
- 유용성과 사전 확률: 이진 분류 과제에서 보상(유용성)의 차이는 사전 확률(Prior)이 변하는 것과 수학적으로 동일한 방식으로 의사결정에 영향을 미침.

2. "순수 지각"에 숨겨진 비용 함수

우리가 단순히 정답을 맞히려고 하는 지각 과정 뒤에도 암묵적인 비용 함수가 작동하고 있음.

- 이산 과제(맞느냐 틀리느냐): 맞으면 1점, 틀리면 0점을 주는 '0-1 유용성 함수'를 사용하며, 사후 확률의 최빈값(MAP)을 고르는 것이 최적
- 연속 과제(수치 추정):
 - 제곱 오차를 최소화하려면 사후 확률의 평균을 선택해야 함.
 - 절대 오차를 최소화하려면 사후 확률의 중앙값을 선택하는 것이 최적.

3. 최적 의사결정을 위한 조건과 한계

- 정확한 사후 확률: 잘못된 가정을 바탕으로 한 확률($q(s|x)$)을 사용하면 장기적으로 기대 유용성을 최대화할 수 없으며, 이는 경제적 손실(더치 북 논증)로 이어짐.
- 현실의 복잡성: 행동의 결과가 확률적으로 나타나는 경우나, 보상이 커질수록 주관적 만족도가 줄어드는 비선형성(한계 효용 체감) 등을 고려해야 함.
- 결정 소음: 인간은 완벽한 계산기처럼 굴지 않으며, 이를 설명하기 위해 유용성이 높은 쪽을 선택할 확률을 높게 잡는 소프트맥스(Softmax) 규칙을 도입.

4. 베이저안 결정 이론의 실제 응용

실험을 통해 인간이 불확실성과 보상을 얼마나 잘 결합하는지 확인한 것.

- 시각 및 도달 운동: 사람들은 자신의 감각적 불확실성이나 신체적 운동 소음을 인지하고, 보상과 벌금 구조에 맞춰 최적의 조준점을 유연하게 변경함.
- 신뢰 구간: 보상 크기와 당첨 확률 사이의 트레이드오프를 활용하여, 피험자가 스스로 자신의 판단이 얼마나 확실한지(신뢰도)를 구간 길이로 표현하도록 유도할 수 있음.

5. 유용성 함수 추론하기

- 주관성: 유용성은 개인마다 다르기 때문에 관찰하기 어려움
- 역 의사결정 이론: 피험자가 내린 수많은 선택 데이터를 바탕으로, 거꾸로 그 피험자가 어떤 유용성 함수(비용 함수)를 최적화하고 있는지 수학적으로 찾아낼 수 있음.